

Санкт-Петербургский Национальный Исследовательский Университет ИТМО

Факультет Программной Инженерии и Компьютерной Техники



Лабораторная работа № 1

по дисциплине «Математическая статистика»

Вариант: 1

Выполнили студенты:

Фам Данг Чунг Нгиа

Поток: **21.1**

Преподаватель: **Иван Кононов**

Санкт-Петербург

2025

I. Задание

1. В файле [iris.csv](#) (здесь и далее ссылки кликабельны) представлены данные о параметрах различных экземплярах цветка ириса. Какой вид в датасете представлен больше всего, какой – меньше? Рассчитайте выборочное среднее, выборочную дисперсию, выборочную медиану и выборочную квантиль порядка $2/5$ для суммарной площади (более точно оценки площади) чашелистика и лепестка всей совокупности и отдельно для каждого вида. Построить график эмпирической функции распределения, гистограмму и box-plot суммарной площади чашелистика и лепестка для всей совокупности и каждого вида.
2. Предположите, какому вероятностному закону соответствует распределение показателя, рассмотренного (расчет выборочных характеристик и визуализация) в задании №1. Оцените параметры данного распределения методом максимального правдоподобия или методом моментов (математическое обоснование оценки строго обязательно). Какими статистическими свойствами обладает найденная оценка (обосновать)? Найти теоретические смещение, дисперсию, MSE (или хотя бы написать теоретические формулы, по которым данные показатели вычисляются, если в итоге получается «очень сложный» интеграл/ряд), информацию Фишера (если определена для вашей модели).

- Пусть P_θ – выбранное в предыдущем задании распределение, параметризуемое вектором θ (пример – равномерное распределение на $[-2\theta; 4\theta]$, $\hat{\theta} = \bar{X}$), $\hat{\theta}$ – оценка параметра θ , полученная в предыдущем упражнении. Проведите численный эксперимент по следующей схеме:
- 3.

- Зафиксируйте конкретное значение $\theta = \theta_0$
- Заведите массив $\{n_1, \dots, n_k\}$ объемов выборки
- Сгенерируйте из распределения P_{θ_0} достаточно большое количество M выборок объема n , где n принимает значения из массива $\{n_1, \dots, n_m\}$. Для каждой сгенерированной выборки вычислите оценку $\hat{\theta}$
- Эмпирически рассмотреть поведение оценки $\hat{\theta}$ в зависимости от объема выборки (можно для каждого объема выборки n_i вывести описательные статистики для оценок, изобразить гистограмму, box-plot, violin-plot).

II. Решение

1. Задание 1

Количество цветков каждого вида ириса в датасете равно 25.

Рассмотрим суммарную площадь как случайную величину.


i. Обработка выборочных данных

Вид ириса	Выборочное среднее	Выборочная дисперсия	Выборочная медиана	Выборочная квантиль порядка 2/5
	$\bar{X}$	S^2	medX	$q_{2/5}$
Setosa	17.98	10.43	17.68	16.72
Versicolor	22.65	18.01	23.10	22.00
Virginica	30.96	34.02	31.95	28.85
Вся совокупность	23.86	241.89	16.73	20.79

ii. Графики

ГРАФИКИ ЭМПИРИЧЕСКОЙ ФУНКЦИИ РАСПРЕДЕЛЕНИЯ


https://colab.research.google.com/drive/14GF3x_ofSUyA7pB3vEfwZBuRln7ZSxnt?usp=sharing




ГИСТОГРАММЫ

<https://colab.research.google.com/drive/1m0yYqlcZ87Wt9fCqxe6WqGJyXIAnG2HS?usp=sharing>


Histogram - Setosa




Histogram - Versicolor



Histogram - Virginica




Histogram - Все виды



BOX-PLOT

<https://colab.research.google.com/drive/1V9pdYRObVXRwU1-NW8OxOkL5hD6aTGon?usp=sharing>



2. Задание 2

і. Гипотеза о распределении данных

На основе анализа гистограмм, эмпирических функций распределения и бокс-плотов, а также расчетов выборочных характеристик, делаем выводы о форме распределения.

Вид ириса	Выборочное среднее $\bar{X}$	Выборочная дисперсия S^2	Выборочная медиана medX	Выборочная квантиль порядка 2/5 $q_{2/5}$
Setosa	17.98	10.43	17.68	16.72
Versicolor	22.65	18.01	23.10	22.00
Virginica	30.96	34.02	31.95	28.85
Вся совокупность	23.86	241.89	16.73	20.79

- **Setosa:**

- Выборочное среднее и медиана близки (17.98 и 17.68), что указывает на симметричность распределения.
- Выборочная дисперсия 10.43 относительно мала, распределение сконцентрировано.
- По гистограмме и box-plot наблюдается слабо выраженная асимметрия вправо, но в целом форма близка к нормальной.

⇒ Для него предположим нормальное распределение: $X_1 \sim N(\mu, \sigma^2)$

- **Versicolor:**

- Среднее (22.65) немного меньше медианы (23.10), что может говорить о слабой асимметрии влево.
- Дисперсия 18.01, разброс умеренный.
- На гистограмме и box-plot видна легкая асимметрия влево, однако форма распределения близка к нормальной.

⇒ Для него предположим нормальное распределение: $X_2 \sim N(\mu, \sigma^2)$

- **Virginica:**

- Среднее (30.96) и медиана (31.95) различаются, что указывает на асимметрию вправо.
- Дисперсия достаточно велика — 34.02.
- Гистограмма и box-plot показывают выраженную асимметрию вправо.

⇒ Для него предположим нормальное распределение: $X_3 \sim N(\mu, \sigma^2)$

- **Вся совокупность:**

- Среднее (23.86) существенно выше медианы (241.89), сильная асимметрия вправо, хвост длинный.
- Однако, если рассматривать совокупность как объединение трёх нормальных распределений ($X = X_1 + X_2 + X_3$), то, согласно центральной предельной теореме, можно предположить, что результирующее распределение стремится к нормальному.
- Кроме того, эмпирическая функция распределения приближается к плавной S-образной форме, а выборка достаточно велика.
- Поэтому, несмотря на наличие асимметрии и больших значений дисперсии, можно рассматривать приближение распределения всей совокупности нормальным законом: $X \sim N(\mu, \sigma^2)$

ii. Оценка параметров распределения (Метод моментов)

Метод моментов заключается в сравнении теоретических моментов распределения к соответствующим выборочным моментам. Для нормального распределения $N(\mu, \sigma^2)$:

- Первый теоретический момент (математическое ожидание): $E[X] = \mu$
- Второй центральный момент (дисперсия): $\text{Var}(X) = E[(X-\mu)^2] = \sigma^2$

Следовательно, оценки по методу моментов:

- $\bar{X}$ — выборочное среднее
- S^2 — несмещённая выборочная дисперсия

Тогда для каждого вида ириса и общей совокупности:

$$\hat{\mu} = \bar{X} \quad , \quad \hat{\sigma}^2 = S^2$$

Вид ириса	$\hat{\mu}$	$\hat{\sigma}^2$
Setosa	17.98	10.43
Versicolor	22.65	18.01

Virginica	30.96	34.02
Вся совокупность	23.86	241.89

iii. Статистические свойства оценок

Свойства	$\hat{\mu}$	$\hat{\sigma}^2$
Несмещенность	несмещенна: $E(\hat{\mu}) = \mu$	несмещенна при использовании знаменателя $n - 1$
Состоятельность	состоятельна по закону больших чисел	сходятся к истинной дисперсии, когда $n \rightarrow \infty$
Эффективность	достигла предела Рао - Крамера	не совсем эффективна, но все же хорошая оценка
Асимптотическая нормальность	удовлетворена в качестве нормального распределения	удовлетворена в качестве нормального распределения

iv. Теоретические смещение, дисперсия, MSE, информация Фишера

	$\hat{\mu}$	$\hat{\sigma}^2$
Теоретическое смещение	$Bias(\hat{\mu}) = 0$	$Bias(\hat{\sigma}^2) = 0$
Теоретическая дисперсия	$Var(\hat{\mu}) = \frac{\sigma^2}{n}$	$Var(\hat{\sigma}^2) = \frac{2\sigma^4}{n-1}$
MSE	$MSE(\hat{\mu}) = Var(\hat{\mu})$	$MSE(\hat{\sigma}^2) = Var(\hat{\sigma}^2)$
Информация Фишера	$I(\mu) = \frac{n}{\sigma^2}$	$I(\sigma^2) = \frac{n}{2\sigma^4}$

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$Var(\hat{\mu}) = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n Var(X_i) = \frac{1}{n^2} * n * \sigma^2 = \frac{\sigma^2}{n}$$

$$\frac{(n-1)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-1}^2 \text{ (chi-square distribution)}$$

$$Q = \frac{(n-1)\hat{\sigma}^2}{\sigma^2}; Var(Q) = 2(n-1)$$

$$Var(\hat{\sigma}^2) = Var\left(\frac{\sigma^2}{n-1} Q\right) = \left(\frac{\sigma^2}{n-1}\right)^2 * Var(Q) = \left(\frac{\sigma^2}{n-1}\right)^2 * 2(n-1) = \frac{2\sigma^4}{n-1}$$

$$MSE(\hat{\mu}) = Bias(\hat{\mu})^2 + Var(\hat{\mu}) = 0 + Var(\hat{\mu}) = Var(\hat{\mu})$$

$$L(x) = \sum_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(X_i - \mu)^2}{2\sigma^2}\right)$$

$$\ln L(x) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$$

$$\frac{d^2}{d\mu^2} L(x) = -\frac{n}{\sigma^2}$$

$$I(\mu) = -E\left(\frac{d^2}{d\mu^2} L(x)\right) = \frac{n}{\sigma^2}$$

$$\frac{d^2}{d(\sigma^2)^2} L(x) = -\frac{n}{2\sigma^4}$$

$$I(\sigma^2) = -E\left(\frac{d^2}{d(\sigma^2)^2} L(x)\right) = \frac{n}{2\sigma^4}$$

3. Задание 3:

<https://colab.research.google.com/drive/1DGLCZTc6JFVFVWqfZAbatqEmjSEpls46?usp=sharing>

Мы предполагаем, что истинное распределение данных имеет вид

$$X \sim N(\mu_0, \sigma_0^2); \mu_0 = 23.86; \sigma_0^2 = 241.89$$

Для различных размеров выборки n ($n = 10, 20, 30, \dots, 100$) выполняется $M = 1000$ независимых повторов эксперимента. Для каждой выборки вычисляются $\hat{\mu}$ и $\hat{\sigma}^2$.

Для каждого размера выборки на основе 1000 экспериментов рассчитываются:


- Среднее значение оценки $\theta = (\hat{\mu}, \hat{\sigma}^2)$
- Смещение оценки: $Bias(\hat{\theta}) = E(\hat{\theta}) - \theta_0$
- Дисперсия оценки: $Var(\hat{\theta})$

- $MSE: MSE(\hat{\theta}) = Bias(\hat{\theta})^2 + Var(\hat{\theta})$

===== Таблица статистики для оценок =====


n	Mean(mu_hat)	Bias(mu_hat)	Var(mu_hat)	MSE(mu_hat)	Mean(sigma2_hat)	Bias(sigma2_hat)	Var(sigma2_hat)	MSE(sigma2_hat)
10	23.930706	0.070706	24.054492	24.059491	243.001772	1.111772	12774.271171	12775.507209
20	23.754430	-0.105570	12.520579	12.531724	240.998775	-0.891225	6062.403640	6063.197922
30	23.708639	-0.151361	8.785284	8.808194	242.762690	0.872690	4224.366698	4225.128286
40	23.817400	-0.042600	5.957100	5.958915	242.681971	0.791971	2972.691139	2973.318356
50	23.891842	0.031842	4.793647	4.794661	244.761587	2.871587	2230.482966	2238.728980
60	23.893115	0.033115	4.437378	4.438475	244.482181	2.592181	1995.031954	2001.751355
70	23.799434	-0.060566	3.376008	3.379676	243.520322	1.630322	1635.273900	1637.931848
80	23.844759	-0.015241	2.906073	2.906305	241.692000	-0.198000	1468.489225	1468.528429
90	23.819588	-0.040412	2.730127	2.731760	242.561794	0.671794	1354.083421	1354.534729
100	23.937318	0.077318	2.527040	2.533018	242.117095	0.227095	1295.319735	1295.371307

Histogram оценки $\hat{\mu}$ по каждому объему выборки n



Результаты моделирования показывают, что средняя оценка $\hat{\mu}$ является несмещенной, когда среднее значение значений $\hat{\mu}$ полученное при разных размерах выборки значение очень близко к реальному $\mu_0 = 23.86$. Более того, с увеличением размера выборки n , распределение $\hat{\mu}$ все более сужающийся, что приводит к значительному снижению дисперсии и MSE, что подтверждает состоятельность и асимптотическую нормальность оценки в соответствии с Центральной предельной теоремой. В то же время гистограммы, связанные с линией KDE, также показывают концентрацию значений $\hat{\mu}$ значение, близкое к реальному, при увеличении n , наглядно иллюстрирует стабильность оценки

Histogram оценки $\hat{\sigma}^2$ по каждому объему выборки n



Для оценки дисперсии $\hat{\sigma}^2$ (рассчитанной по знаменателю $n-1$, чтобы гарантировать несмещенность) результат моделирования показывает, что среднее значение $\sigma_0^2 = 241.89$, а дисперсия оценки $\hat{\sigma}^2$ уменьшается с увеличением размера выборки. Это показывает, что оценка $\hat{\sigma}^2$ имеет несмещенность и является состоятельной, хотя ее вариация, естественно, превышает среднюю оценку. Уменьшение дисперсии оценки $\hat{\sigma}^2$ также демонстрирует эффективность оценки при большой выборке, а также подтверждает ее асимптотический сравнительный анализ в соответствии со статистическими теоремами.