

Санкт-Петербургский Национальный Исследовательский Университет ИТМО

Факультет Программной Инженерии и Компьютерной Техники



Лабораторная работа № 3

по дисциплине «Математическая статистика»

Вариант: 3

Выполнили студенты:

Фам Данг Чунг Нгиа

Поток: **21.1**

Преподаватель: **Иван Кононов**

Санкт-Петербург

2025

I. Задание

Для каждой проблемы нужно провести два статистических теста, если не сказано иное, причем первый из критериев нужно реализовать самостоятельно (считать и выводить значение статистики, критическое значение, p-value), в качестве второго можно воспользоваться готовой реализацией. Также нужно отдельно указывать, как формализуются H_0 и H_1 для выбранных тестов. Уровень значимости выбираете сами. Советую для выполнения использовать Python или R.

Вариант 3

В [датасете](#) приведены данные о результатах вступительных экзаменов

1. Предположите с каким вероятностным законом распределен суммарный балл за экзамены. С помощью стат. теста подтвердите/опровергните это предположение (первый тест – критерий согласия Колмогорова, если распределение абсолютно непрерывное, либо критерий согласия Пирсона хи-квадрат, если распределение дискретное).
2. Верно ли, что распределение балла по математике и чтению одинаково (первый тест – критерий однородности Колмогорова-Смирнова, или хи-квадрат, или f-тест + t-тест)?
3. Верно ли, что прослушавшие подготовительные курсы лучше сдали экзамены (первый тест – критерий на один из коэффициентов корреляции)?

II. Решение

1. Задание 1:

- H_0 - Нулевая гипотеза : Суммарный балл распределён по нормальному закону с параметрами мат. ожидания и станд. откл.
- H_1 - Альтернативная гипотеза : Распределение отлично от нормального.

Данные о суммарных баллов включают только дискретные целые значения, например, 193, 241, 278,... и не содержат действительного числа. Таким образом, мы рассматриваем это как дискретное распределение и будем использовать **критерий согласия Пирсона χ^2** для его проверки гипотезы.

Число наблюдений: $m = 500$

Среднее значение: $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i = 201,78$

Стандартное отклонение: $s = \sqrt{\frac{1}{N-1} \cdot \sum_{i=1}^N (x_i - \bar{x})^2} = 44,56$

Разбито на 8 интервалов с границами:

$$\text{width} = \frac{\max(x_i) - \min(x_i)}{8} = \frac{300 - 78}{8} \approx 28$$

У нас будут такие интервалы:

(77, 105], (105, 133], (133, 161], (161, 189], (189, 217], (217, 245], (245, 273], (273, 301]

Формулы расчёта пробабилитетов и ожидаемых частот:

$$z_i = \frac{a_i - \bar{x}}{s}, \quad p_i = \Phi(z_i) - \Phi(z_{i-1}), \quad E_i = mp_i$$

№	Интервал	n_i	z_i	p_i	E_i	$\frac{(n_i - E_i)^2}{E_i}$
1	(77, 105]	7	-2.17	0.01	6.19	0.11
2	(105, 133]	18	-1.54	0.05	23.20	1.17
3	(133, 161]	77	-0.92	0.12	59.35	5.25
4	(161, 189]	97	-0.29	0.21	103.55	0.41
5	(189, 217]	114	0.34	0.25	123.28	0.70
6	(217, 245]	97	0.97	0.20	100.15	0.10
7	(245, 273]	59	1.60	0.11	55.52	0.22
8	(273, 301]	31	2.23	0.04	21.00	4.77

$$\chi^2 = \sum_{i=1}^8 \frac{(n_i - E_i)^2}{E_i} = 12,72$$

Степени свободы: $r = 8$ интервалов, $l = 2$ параметра оценено $\rightarrow df = r - l - 1 = 5$

Трассировка из таблицы ($\alpha=0,05$): $\chi^2_{0,95}(5) = 11,07$

α	0.600	0.667	0.750	0.800	0.875	0.900	0.950	0.975	0.990	0.995	0.999
n											
1	0.708	0.936	1.323	1.642	2.354	2.706	3.841	5.024	6.635	7.879	10.828
2	1.833	2.197	2.773	3.219	4.159	4.605	5.991	7.378	9.210	10.597	13.816
3	2.946	3.405	4.108	4.642	5.739	6.251	7.815	9.348	11.345	12.838	16.266
4	4.045	4.579	5.385	5.989	7.214	7.779	9.488	11.143	13.277	14.860	18.467
5	5.132	5.730	6.626	7.289	8.625	9.236	11.070	12.833	15.086	16.750	20.515
6	6.211	6.867	7.841	8.558	9.992	10.645	12.592	14.449	16.812	18.548	22.458
7	7.283	7.992	9.037	9.803	11.326	12.017	14.067	16.013	18.475	20.278	24.322

Вывод:

Так как:

$$\chi^2 = 12,72 \geq \chi^2_{0,95}(5) = 11,07$$

гипотеза H_0 отвергается (Суммарные баллы не следуют нормальному распределению).


Мы используем таблицы распределения Хи - квадрата:

- $\chi^2_{(1)} = 11,07 \rightarrow p - \text{value}_{(1)} = 0,05 = p_1$
- $\chi^2_{(2)} = 12,83 \rightarrow p - \text{value}_{(2)} = 0,025 = p_2$

$$\Rightarrow p - \text{value} = p_1 + \frac{x_1 - x}{x_1 - x_2} (p_2 - p_1) = 0,05 + \frac{11,07 - 12,72}{11,07 - 12,83} (0,025 - 0,05) \approx 0,0266$$

Программа критерия созданная с помощью библиотеки Python:

<https://colab.research.google.com/drive/1OnQAYO0HiChMUTFRabtK8XMVJeMXY5i-?usp=sharing>



2. Задание 2:

- H_0 - Нулевая гипотеза : Распределение баллов по математике (math score) такое же, как и распределение баллов по чтению (reading score)
- H_1 - Альтернативная гипотеза : Их распределения различны.

Мы будем использовать **критерий однородности Колмогорова-Смирнова**. У нас есть 2 выборки с объемом $m = n = 500$. Мы объединяем эти две выборки и сортируем их по возрастанию величины.

sorted combined columns (no duplicates)	$F_m(z_i)$	$G_n(z_i)$	D_i
14	0.002	0	0.002
19	0.004	0	0.004
27	0.006	0	0.006
...			
61	0.428	0.322	0.106

...			
99	0.984	0.982	0.002
100	1	1	0

$$F_m(z_i) = \frac{\sum (x_{(\text{math}) i} \leq x_i)}{m}$$

$$G_n(z_i) = \frac{\sum (x_{(\text{reading}) i} \leq x_i)}{n}$$

$$D_i = |F_m(z_i) - G_n(z_i)|$$

$$D = \max_i D_i = 0.106$$

Согласно теории, при $m, n \rightarrow \infty$ статистика $D \cdot \sqrt{\frac{m \cdot n}{m+n}}$ сходится к стандартному распределению Колмогорова.

Квантиль распределения Колмогорова ($\alpha=0,05$): $k_{0,95} = 1.36$

Вывод:

Так как:

$$D \cdot \sqrt{\frac{m \cdot n}{m+n}} = 0.106 \sqrt{\frac{500 \cdot 500}{500 + 500}} \approx 2.37 > k_{0,95}$$

, гипотеза H_0 отвергается (Распределение баллов по математике (math score) и распределение баллов по чтению (reading score) не одинаковы).

Программа критерия созданная с помощью библиотеки Python:

<https://colab.research.google.com/drive/1ODyshRho9j3GJjxT8cpwzmMpJZMmqSCx?usp=sharing>

```

Choose Files exams_dataset.xlsx
• exams_dataset.xlsx(application/vnd.openxmlformats-officedocument.spreadsheetml.sheet) - 101659 bytes, last modified: 5/24/2025 - 100% done
Saving exams_dataset.xlsx to exams_dataset (1).xlsx
Результаты критерия Колмогорова-Смирнова (две выборки):
Статистика D: 0.1060
Критическое значение D_crit: 0.0860
p-значение: 0.0072
Нулевая гипотеза отвергается: распределения различаются.

```

3. Задание 3:

“Проверить, существует ли статистическая связь между прохождением подготовительных курсов и результатами экзамена (суммарный балл)”

- Переменная 1: **test preparation course** — категориальная, закодирована как:

- "completed" → 1 (прошёл курс)
- "none" → 0 (не прошёл курс)
- Переменная 2: **sum_score** — числовая (сумма трёх предметов)
Объём выборки: $n = 500$

test preparation course	done course (r_i)	sum score	rank score (s_i)	$s_i - r_i$	$(s_i - r_i)^2$
none	0	242	122.5	122.5	15006.25
none	0	193	344	344	118336
completed	1	241	125	124	15376
none	0	278	30	30	900
...					

Используется **коэффициент ранговой корреляции Спирмена**.

$$\rho = 1 - \frac{6 \sum (s_i - r_i)^2}{n(n^2 - 1)} = 1 - \frac{6 * 1936078}{500(500^2 - 1)} \approx 0.1447$$

H_0 : корреляции нет (две переменные независимы)

При $n = 500$, $\alpha = 0.05$: $c_1 \approx 0.0877$

Вывод:

Так как: $\rho > c_1$, гипотеза H_0 отвергается (Существует слабая, но статистически значимая положительная корреляция ρ : учащиеся, прошедшие подготовительные курсы, в среднем сдали экзамен лучше).

Программа критерия созданная с помощью библиотеки Python:

https://colab.research.google.com/drive/1nbokvLSUEXF9qRjbDdq_4NwuEQXZkxFF?usp=sharing

```

Choose Files exams_dataset.xlsx
• exams_dataset.xlsx(application/vnd.openxmlformats-officedocument.spreadsheetml.sheet) - 195800 bytes, last modified: 5/24/2025 - 100% done
Saving exams_dataset.xlsx to exams_dataset (2).xlsx
Результаты ранговой корреляции Спирмена:
Коэффициент корреляции (ρ): 0.1447
p-значение: 0.0012
Нулевая гипотеза отвергается: между курсами и результатами есть статистическая зависимость.
Интерпретация: те, кто прошли курсы, сдали лучше.

```