

Санкт-Петербургский Национальный Исследовательский Университет ИТМО

Факультет Программной Инженерии и Компьютерной Техники



Лабораторная работа № 4

по дисциплине «Математическая статистика»

Вариант: 11

Выполнили студенты:

Фам Данг Чунг Нгиа

Поток: **21.1**

Преподаватель: **Иван Кононов**

Санкт-Петербург

2025

I. Задание

Задание 1

Задание представлено в 4 вариантах. Для каждого варианта требуется построить линейную модель (предполагая нормальность распределения ошибок, некоррелированность компонент, гомоскедастичность), вычислить оценки коэффициентов модели и остаточной дисперсии, построить для них доверительные интервалы, вычислить коэффициент детерминации, проверить указанные в условии гипотезы с помощью построенной линейной модели. Проверьте остатки на нормальность.

Вариант 1. В файле <https://drive.google.com/file/d/1vv2jGNp6EO8HHRoscDRQU90faR3j8iTN/view> представлены данные о продажах различных авто.

1. Постройте линейную модель, где в качестве независимых переменных выступают расход в городе, расход на шоссе, мощность (вместе со свободным коэффициентом), зависимой – цена.
2. Проверьте следующие подозрения:
 - Чем больше мощность, тем больше цена
 - Цена изменяется в зависимости от расхода в городе
 - Проверьте гипотезу H_0 о равенстве одновременно нулю коэффициентов при расходе в городе и расходе на шоссе против альтернативы $H_1 = \overline{H_0}$

Задание 2

Для каждого варианта требуется проверить гипотезу о равенстве средних на каждом уровне фактора с помощью модели однофакторного дисперсионного анализа

Указание: реализовать самим

Вариант 1. В файле <https://drive.google.com/file/d/1CSChMzjberRwgcf90BBu-J6uxMg-Qf7/view> представлены данные об ирисках. Фактор – подвид. Выходная переменная – суммарная площадь (точнее оценка площади) чашелистика и лепестка.

II. Решение

1. Задание 1:

Мы получаем данные из таких столбцов таблицы следующим образом:

Price (Y)	MPG.city (X1)	MPG.highway (X2)	Horsepower (X3)
15.9	25	31	140
33.9	18	25	200
29.1	20	26	172
37.7	19	26	172
30	22	30	208
15.7	22	31	110
20.8	19	28	170
23.7	16	25	180
26.3	19	27	170
34.7	16	25	200
40.1	16	25	295
13.4	25	36	110
11.4	25	34	110
15.1	19	28	160
15.9	21	29	110
16.3	18	23	170
16.6	15	20	165
18.8	17	26	170
38	17	25	300
18.4	20	28	153

Посмотрим линейную модель:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \hat{\beta}_3 x_{i3}$$

при $x_1 = \text{MPG.city}$, $x_2 = \text{MPG.highway}$, $x_3 = \text{Horsepower}$

Мы используем метод наименьших квадратов для нахождения коэффициентов

Матричная форма линейного модели:

$$Y = X\beta + \varepsilon$$
$$X = \begin{pmatrix} 1 & X_{11} & X_{12} & X_{13} \\ 1 & X_{21} & X_{22} & X_{23} \\ \dots & \dots & \dots & \dots \\ 1 & X_{n1} & X_{n2} & X_{n3} \end{pmatrix}, \text{ при } x_0 = \begin{pmatrix} 1 \\ 1 \\ \dots \\ 1 \end{pmatrix}$$

Мы рассчитываем следующие значения (с помощью excel):

Формула:

$$X^T X = \begin{pmatrix} n & \sum x_1 & \sum x_2 & \sum x_3 \\ \sum x_1 & \sum x_1^2 & \sum x_1 x_2 & \sum x_1 x_3 \\ \sum x_2 & \sum x_1 x_2 & \sum x_2^2 & \sum x_2 x_3 \\ \sum x_3 & \sum x_1 x_3 & \sum x_2 x_3 & \sum x_3^2 \end{pmatrix}$$

После расчета:

$$X^T X = \begin{pmatrix} 93 & 2080 & 2705 & 13376 \\ 2080 & 49426 & 63101 & 280948 \\ 2705 & 63101 & 81293 & 373151 \\ 13376 & 280948 & 373151 & 280948 \end{pmatrix}$$

Формула:

$$X^T Y = \begin{pmatrix} \sum Y \\ \sum x_1 Y \\ \sum x_2 Y \\ \sum x_3 Y \end{pmatrix}$$

После расчета:

$$X^T Y = \begin{pmatrix} 1814.4 \\ 37610.8 \\ 50117.1 \\ 297647.8 \end{pmatrix}$$

Оценка коэффициентов модели:

$$\hat{\beta} = (X^T X)^{-1} X^T Y = \begin{pmatrix} 45.07 \\ -1.108 \\ 0.024 \\ -0.01 \end{pmatrix}$$


Для каждой строки подсчитаем: ($i = 0, 1, 2, 3$)

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot X_{i1} + \hat{\beta}_2 \cdot X_{i2} + \hat{\beta}_3 \cdot X_{i3}$$

Остаточная дисперсия:

$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i$$

Мы строим гистограмму распределения остаточной дисперсии:



По построенному выше графику, остаточная дисперсия не соответствует нормальному распределению.

Квадрат коэффициента корреляции:

$$R^2 = 1 - \frac{\sum \hat{\epsilon}_i^2}{\sum (Y_i - \bar{Y})^2} = 0.31$$

Дисперсия остатков:

$$S^2 = \frac{\sum \hat{\epsilon}_i^2}{n - k - 1} = \frac{5924.8}{93 - 3 - 1} \approx 66.57$$

Доверительные интервалы уровня $1 - \alpha$ ($\alpha = 0.05$) для коэффициентов $\hat{\beta}_i$:

$$\hat{\beta}_i \pm t_{1-\frac{\alpha}{2}} \cdot \sqrt{S^2 [(X^T X)^{-1}]_{(i+1)(i+1)}}$$

при $(X^T X)^{-1} = \begin{pmatrix} 0.429 & 0.022 & -0.032 & 0 \\ 0.022 & 0.003 & -0.003 & 0 \\ -0.032 & -0.003 & 0.004 & 0 \\ 0 & 0 & 0 & 0.001 \end{pmatrix}$ и $t_{0.975} = 1.96$

Тогда $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3$ соответственно имеют эти доверительные интервалы:

$$(34.596, 55.544), (-1.984, -0.232), (-0.987, 1.035), (-0.516, -0.496)$$

Статистическая гипотеза:

$$H_0: \beta_i = 0, \quad H_1: \beta_i \neq 0$$

Формула статистики:

$$t_{\beta_i} = \frac{\hat{\beta}_i - \beta_i}{\sqrt{S^2[(X^T X)^{-1}]_{(i+1)(i+1)}}} = \frac{\hat{\beta}_i - 0}{\sqrt{S^2[(X^T X)^{-1}]_{(i+1)(i+1)}}}$$

После расчета:

$$|t_{\beta_0}| = 8.43 > t_{0.975, 89} = 1.987 \text{ (отвергаем } H_0, \beta_0 \text{ обладает статистической значимостью)}$$

$$|t_{\beta_1}| = 2.48 > t_{0.975, 89} = 1.987 \text{ (отвергаем } H_0, \beta_1 \text{ обладает статистической значимостью)}$$

$$|t_{\beta_2}| = 0.047 < t_{0.975, 89} = 1.987 \text{ (не отвергаем } H_0, \beta_2 \text{ не обладает статистической значимостью)}$$

$$|t_{\beta_3}| = 0.039 < t_{0.975, 89} = 1.987 \text{ (не отвергаем } H_0, \beta_3 \text{ не обладает статистической значимостью)}$$

Мы используем тест Фишера для проверки:

Статистическая гипотеза:

$$H_0: \beta_1 = \beta_2 = 0, \quad H_1: \beta_i \neq 0$$

Расчет:

Степень свободы: $k - 1 = 3 - 1 = 2$; $n - k = 93 - 3 - 1 = 89$

$$SS^{\text{in}} = \frac{1}{n - k} \sum_{i,j} (x_{ij} - \bar{X}_i)^2 = 1489.07$$

$$SS^{\text{ex}} = \sum_j \frac{n_j}{k - 1} (\bar{X}_j - \bar{X})^2 = 1360.98$$

$$F = \frac{SS^{\text{ex}}(n - k)}{SS^{\text{in}}(k - 1)} \approx 0.80 < F_{0.95}(2, 89) \approx 3.10$$

Вывод задания 1:

1. Чем больше мощность, тем больше цена

$$\hat{\beta}_3 = 0.024 > 0,$$

$$|t_{\beta_3}| = 0.039 < t_{0.975,89} = 1.987 \text{ (} \beta_3 \text{ не обладает статистической значимостью)}$$

=> Отвергаем эту гипотезу.

(Мощность не влияет на цену на статистически значимом уровне.)

2. Цена изменяется в зависимости от расхода в городе

$$\hat{\beta}_1 = -1.108 < 0,$$

$$|t_{\beta_1}| = 2.48 > t_{0.975,89} = 1.987 \text{ (} \beta_1 \text{ обладает статистической значимостью)}$$

=> Цена статистически зависит от расхода в городе (чем выше расход, тем ниже цена).

3. Проверьте гипотезу H_0 о равенстве одновременно нулю коэффициентов при расходе в городе и расходе на шоссе против альтернативы $H_1 = \overline{H_0}$:

Из предыдущего теста F:

$$F = \approx 0.80 < F_{0,95}(2, 89) \approx 3.10$$

=> Недостаточно оснований утверждать, что обе переменные `MPG.city` и `MPG.highway` одновременно влияют на цену автомобиля.

2. Задание 2:

Гипотеза:

$$H_0: \mu_1 = \mu_2 = \mu_3$$

H_1 : есть по крайней мере одна другая группа

Фактор: подвид (*setosa*, *versicolor*, *virginica*)

Выходная переменная: суммарная площадь чашелистика и лепестка по формуле:

$$S_i = \text{SepalLength} \times \text{SepalWidth} + \text{PetalLength} \times \text{PetalWidth}$$

Количество наблюдения: $n = 150$

Количество подвида: $k = 3$

Мы используем тест Фишера для проверки дисперсии:

$$SS^{\text{in}} = \frac{1}{n - k} \sum_{i,j} (x_{ij} - \bar{X}_i)^2 = 2162.794$$

$$SS^{\text{ex}} = \sum_j \frac{n_j}{k - 1} (\bar{X}_j - \bar{X})^2 = 1499.236$$

$$F = \frac{SS^{\text{ex}}(n - k)}{SS^{\text{in}}(k - 1)} \approx 106.03 > F_{0,95}(2, 147) \approx 3.06$$

Вывод задания 2:

Гипотеза H_0 отвергается на уровне значимости $\alpha=0,05$.

Существует статистически значимая разница между видами ирисов по среднему значению суммарной площади (чашелистика + лепестка).