

Домашнее Задание 2

...И немного теории, что не уместилось в пару практики

1 Выборка и статистики

1.1 Выборка

Важнейшим объектом такого раздела как статистика является *выборка*. С точки зрения теории это просто совокупность взаимно-независимых случайных величин $X = (X_k)_{k=1}^m$ — *реализаций* случайной величины ξ (при любом k , X_k равен по распределению ξ), которую называют *генеральной совокупностью*. *Размером выборки* m назовём число элементов в ней. Если зафиксировать размер выборки, то мы по сути рассматриваем какое-то измеримое пространство, которое называется *выборочным*.

Отмечу, что требование взаимной независимости критично для построения теории (не жалуйтесь потом, если применяли оценки матстата к выборке с зависимыми измерениями, и получилось, что ничего не получилось). Часто на практике это предположение означает следующее: мы измеряем одни и те же численные параметры какого-то события, и различным измерениям соответствуют различные события.

Например, если мы измеряем артериальное давление у человека, то измерения должны проводиться на разных людях в одинаковых условиях. Измерять давление у одного и того же человека в разные дни может быть приемлемо, если мы говорим, например о различных генеральных совокупностях (до и после принятия лекарства). Если два раза подряд померить давление у одного и того же человека не меняя условия, то данные явно зависимы, поэтому должны быть исключены.

1.2 Статистики

Статистикой будем называть любую измеримую (борелевскую) функцию на выборочном пространстве. На практике преимущественно будем говорить о борелевских функциях $T : \mathbb{R} \rightarrow \mathbb{R}$. Требование измеримости нам нужно чтобы мы могли посчитать вероятности различных событий связанных с нашей статистикой, например $\mathbb{P}(T(X) < 0)$. Далее рассмотрим примеры статистик, а также некоторых характеристик выборки, основанных на них.

2 Вариационный ряд, ЭФР и их друзья

2.1 Вариационный ряд

Для начала введём понятие вариационного ряда. Допустим, мы упорядочим все наши измерения по возрастанию. Статистику отвечающую наименьшему значению будем обозначать $X_{(1)}$. Следующему $X_{(2)}$. И так далее вплоть до $X_{(m)}$. Называться они будут соответственно *первой порядковой статистикой*, *второй* и так далее. Совокупность этих статистик называется *вариационным рядом*.

Для элементов вариационного ряда можно даже построить законы распределения. Например:

$$F_{X_{(m)}}(x) = \mathbb{P}(X_{(m)} \leq x) = \mathbb{P}\left(\max_k X_k \leq x\right) = \prod_{k=1}^m \mathbb{P}(X_k \leq x) = (F_X(x))^m$$

Если интересно, то можете самостоятельно посчитать распределение остальных элементов вариационного ряда.

2.2 Эмпирическое Распределение

Эмпирическим распределением назовём вероятностную меру определённую следующим образом:

$$\mathbb{P}_m(B) := \frac{\nu(B)}{m} = \frac{\sum_k \mathbb{1}(X_k \in B)}{m}$$

Где B — событие из сигма-алгебры, а $\nu(B)$ — число элементов выборки попавших в B . Часто такую вероятность называют *относительной частотой*.

К примеру, мы можем рассмотреть событие, показывающее, как часто встречаются элементы выборки с тем или иным значением:

$$\mathbb{P}_m(X_{(1)}) = \frac{\sum_k \mathbb{1}(X_k = X_{(1)})}{m}$$

2.3 Эмпирическая Функция Распределения

Эмпирической функцией распределения назовём функцию:

$$F_m(x) := P_m(-\infty; x] = \frac{\sum_k \mathbb{1}(X_k \leq x)}{m}$$

Это по сути приближение функции распределение закона генеральной совокупности. Следующая теорема доказывает то, что интуиция нас не подводит. А именно, уточняет характер сходимости последовательности выборочных функций распределения к функции распределения закона генеральной совокупности при $m \rightarrow \infty$. Заметьте, что из этого следует сходимость почти наверное эмпирического распределения к исходному.

2.3.1 Теорема Гливенко-Кантелли

Пусть заданы функция распределения закона генеральной совокупности F_ξ и эмпирическая функция распределения. Тогда:

$$\sup_{x \in \mathbb{R}} |F_\xi(x) - F_m(x)| \xrightarrow[n \rightarrow \infty]{a.s.} 0$$

2.4 Гистограмма

Теперь поговорим о том, как можно удобно это всё визуализировать. Для начала определимся с вероятным типом нашего распределения. Если много повторных измерений, то это может сигнализировать нам о том, что распределение дискретное. Так, эмпирическое распределение будет существенно сосредоточено в отдельных точках. Если же повторных измерений очень мало, то, вероятно, мы имеем дело с непрерывным распределением.

Сразу оговорюсь, что данные должны согласовываться с какой-то заранее известной моделью. Если Вы ожидаете увидеть непрерывное распределение, а получили измерения с большим числом повторов (или наоборот), то это не повод для работы с дискретным распределением, а красный флаг, сигнализирующий о том, что с исходной моделью что-то не то! На этом этапе лучше не делать никакие выводы, а пересмотреть модель или способ сбора данных.

Так, если у вас получилось, что измерения скорости автомобиля строго дискретны (например пики частот по целым значениям), то, возможно, следует либо учитывать это в модели и рассматривать дискретное распределение (что противоречит природе процесса), либо использовать более точные методы подсчёта.

Возвращаясь к самой визуализации. В дискретном случае всё просто. Каждому значению мы сопоставляем его относительную частоту (можно и просто число появлений каждого результата, это влияет только на масштаб). Если же распределение непрерывно или в нём очень много измерений, то можно поступить так: разбить отрезок $[X_{(1)}, X_{(m)}]$ на равные непересекающиеся части. Пусть их число равно k . Тогда наш отрезок на равные части будут разделять точки:

$$X_{(1)}, X_{(1)} + \frac{X_{(m)} - X_{(1)}}{k}, X_{(1)} + 2\frac{X_{(m)} - X_{(1)}}{k}, \dots, X_{(m)}$$

Так каждому отрезку сопоставим его относительную частоту:

$$\mathbb{P}_m[a, b] = \frac{\sum_k \mathbb{1}(X_k \in (a, b])}{m}$$

Получившийся по итогу столбчатый график называется *гистограммой*.

3 Выборочные Среднее и Дисперсия

3.1 Среднее

Теперь поговорим о ещё двух очень важных статистиках. Первая — *выборочное среднее*. Это приближение математического ожидания. Определяется оно так:

$$\bar{X} := \frac{1}{m} \sum_{k=1}^m X_k$$

По своей сути это приближение математического ожидания. Это прямо следует из Закона Больших Чисел.

$$\bar{X} \xrightarrow[m \rightarrow \infty]{a.s.} \mathbb{E}\xi$$

Для этой статистики можно также подсчитать ожидание и дисперсию (которые имеют смысл при существовании/конечности оных у распределения генеральной совокупности):

$$\begin{aligned} \mathbb{E}\bar{X} &= \mathbb{E}\left(\frac{1}{m} \sum_{k=1}^m X_k\right) = \frac{1}{m} \sum_{k=1}^m \mathbb{E}X_k = \frac{1}{m} \sum_{k=1}^m \mathbb{E}\xi = \frac{m}{m} \mathbb{E}\xi = \mathbb{E}\xi \\ \mathbb{D}\bar{X} &= \mathbb{D}\left(\frac{1}{m} \sum_{k=1}^m X_k\right) = \frac{1}{m^2} \sum_{k=1}^m \mathbb{D}X_k = \frac{1}{m^2} \sum_{k=1}^m \mathbb{D}\xi = \frac{\mathbb{D}\xi}{m} \xrightarrow{m \rightarrow \infty} 0 \end{aligned}$$

Что, в принципе, согласуется с Законом Больших Чисел и неравенством Чебышева.

3.2 Дисперсия

Следующей статистикой будет приближение дисперсии. А именно, *выборочная дисперсия*. Она определяется так:

$$S^2 := \frac{1}{m} \sum_{k=1}^m (X_k - \bar{X})^2$$

Можно показать, что выборочная дисперсия действительно приближает дисперсию генеральной совокупности.

$$S^2 \xrightarrow[m \rightarrow \infty]{a.s.} \mathbb{D}\xi$$

Вывод математического ожидания и дисперсии этой статистики опять же достаточно громоздкий, так что я приведу лишь конечные формулы.

$$\mathbb{E}S^2 = \left(1 - \frac{1}{m}\right) \mathbb{D}\xi \xrightarrow{m \rightarrow \infty} \mathbb{D}\xi$$

$$\mathbb{D}S^2 = \frac{1}{m-1} \left(\mathbb{E}(\xi - \mathbb{E}\xi)^4 - \frac{n-3}{n-1} (\mathbb{D}\xi)^2 \right) \xrightarrow{m \rightarrow \infty} 0$$

Здесь интересно то, что ожидание выборочной дисперсии не равно в точности дисперсии закона генеральной совокупности. Это не приятно, хоть и не страшно. И это легко исправляется домножением выборочной дисперсии на $\frac{m}{m-1}$ (проверьте). Такая статистика называется *исправленной выборочной дисперсией*.

1: Задача на подумать

В [исследовании](#) о влиянии образования на качество жизни участвовало 2131 человек возрастом 15-49 лет; 2933 человек возрастом 50-59 лет; 3436 человек в возрасте 60-69 лет; 1855 старше 70 лет (для решения предположите, что средний возраст в этой категории равен 75).

Считая, что в этих 4 группах люди распределены по возрасту примерно равномерно:

- 1) Постройте вариационный ряд, ЭФР и гистограмму для оценки возраста членов выборки.
- 2) Найдите выборочное среднее, дисперсию, медиану и квартили.

2: Задача на подумать 2

Рассмотрим [рыночную капитализацию](#) маленькой компании по производству видеокарт в 2015-2022 годах. Данные представлены в табличке ниже.

- 1) Постройте вариационный ряд, ЭФР и гистограмму для оценки возраста членов выборки.
- 2) Найдите выборочное среднее, дисперсию, медиану и квартили.

Капитализация (в млрд. долл.)	17.73	57.53	117.26	81.43	144	323.24	735.27	364.18
Год	2015	2016	2017	2018	2019	2020	2021	2022

3: Задача на подумать 3*

- 1) Посчитайте матожидание выборочной дисперсии и исправленной выборочной дисперсии.
- 2**) Подумайте над аналогами выборочных среднего и дисперсии для векторных случайных величин. Ключевое свойство: должна сохраняться сходимость почти наверное к матожиданию и ковариационной матрице генеральной совокупности соответственно.