

Домашнее Задание 3

...и страшные свойства оценок параметров...

1 Задача оценки параметров

1.1 Небольшой пример

Допустим у вас есть модель какого-то явления. Например, известно, что начальная зарплата у студентов одной специальности сразу после выпуска из университета подчиняется **логнормальному распределению**. Однако, у разных специальностей различные зарплатные вилки. Как это учесть в нашей модели?

Наверное, из огромного семейства кривых описывающих самые разные логнормальные распределения было бы славно выбрать одну, соответствующую вполне конкретному распределению (например, распределению зарплат программистов). Из теории вероятностей известно, что конкретный вид кривой логнормального распределения определяется двумя числами: $\mu \in \mathbb{R}$ и $\sigma^2 > 0$. То есть, задав эти два числа мы зададим конкретное распределение. Имея распределение мы можем прикинуть вилку, в которой, вероятностью 0.95 будет лежать зарплата выпускника (и потом это число пихать на все рекламные баннеры).

Допустим теперь, что мы собрали какие-то данные, например зарплаты устроившихся на работу выпускников бакалавриата мегафакультета КТиУ ИТМО за 2024 год. Как имея конкретные числа оценить параметры распределения?




Рис. 1: Графики плотностей логнормального распределения при $\mu = 0$ и различных σ

1.2 Постановка задачи оценки параметров

Рассмотрим строгую постановку задачи оценки параметров. Допустим, у нас есть выборка X из какой-то генеральной совокупности ξ с функцией распределения зависящей от каких-то параметров: $F_\xi(x) = F_\xi(\theta, x)$. Где $\theta \in \Theta \subset \mathbb{R}^d$.

Возвращаясь к логнормальному распределению, если переобозначить параметры μ и σ^2 как θ_1 и θ_2 , то функция распределения представима в следующем виде:

$$F_\xi(\theta, x) = \Phi\left(\frac{\ln x - \theta_1}{\theta_2}\right)$$

Где $\theta = (\theta_1, \theta_2) \in \mathbb{R}_{>0} \times \mathbb{R} \subset \mathbb{R}^2$.

Задача оценки параметров определяется, как задача построения такой статистики $\hat{\theta}_m = \hat{\theta}_m(X)$, что $\hat{\theta}_m \approx \theta$. Как именно понимать это "примерно равно" мы поговорим когда будем рассматривать свойства этих статистик. Есть даже алгоритмы построения "хороших" оценок, но об этом мы поговорим на следующих занятиях.

Но уже сейчас можно попробовать хотя бы прикинуть, как примерно оценить параметры логнормального распределения. Если присмотреться к функции распределения, то можно заметить, что логарифм случайной величины распределён как какое-то нормальное распределение. Так может быть, выборочное среднее логарифма и выборочная дисперсия логарифма будут являться хорошим приближением значений наших параметров?

$$\mu \approx \overline{\ln X}$$

$$\sigma^2 \approx \overline{(\ln X - \overline{\ln X})^2}$$

2 Свойства Оценок Параметров

Чтобы понять, является ли оценка хорошей были предложены следующие свойства. Сразу оговорюсь, что тут представлены не все свойства, а необходимый минимум. Постепенно, на дальнейших занятиях, оценки будут обрастать всё новыми и новыми свойствами.

2.1 Состоятельность

Первое и самое главное свойство — состоятельность. Оно говорит о том, как наша оценка сходится к параметру. Она бывает двух видов: обычная и сильная.

Назовём оценку *состоятельной* если она по вероятности сходится к параметру, или:

$$\forall \varepsilon > 0 : \mathbb{P}(|\hat{\theta}_m - \theta| > \varepsilon) \xrightarrow{m \rightarrow \infty} 0$$

Как правило, если оценка не является состоятельной, то её не рассматривают — теряется смысл исходной формулировки $\hat{\theta}_m \approx \theta$. Сходимости по распределению нам недостаточно, так как такой вид сходимости ничего не говорит о совместном распределении статистики и параметра генеральной совокупности.

В свою очередь, назовём оценку *сильно состоятельной*, если статистика сходится к параметру почти наверное:

$$\mathbb{P}\left(\lim_{m \rightarrow \infty} \hat{\theta}_m(X) \neq \theta\right) = 0$$

Для доказательства этих свойств можно пользоваться, например, Законом Больших Чисел. Либо же, если известно распределение параметра, можно попробовать расписать по определению.

Выборочное среднее, выборочная дисперсия являются сильно состоятельными оценками. Все выборочные моменты, а также выборочные квантили являются состоятельными.

2.2 Несмещённость

Следующим важным свойством является *несмещённость*. Она говорит о том, что ожидание статистики равно значению параметра.

$$\mathbb{E}\hat{\theta}_m = \theta$$

Это свойство означает то, что наша оценка правильна "в среднем". На нём основываются некоторые принципы сравнения оценок, о которых мы поговорим далее.

Примерами несмещённых оценок являются матожидание, исправленная выборочная дисперсия.

Однако на практике, это свойство не выполняется, а выполняется другое, более слабое:

$$\mathbb{E}\hat{\theta}_m \xrightarrow{m \rightarrow \infty} \theta$$

Такое свойство называется *асимптотической несмещённостью*. Для асимптотически несмещённых оценок важным параметром является *величина смещения*, которая говорит о том, как в среднем оценка отклоняется от параметра.

$$b_m(\theta) = |\mathbb{E}\hat{\theta}_m - \theta|$$

Асимптотически несмещённой является выборочная дисперсия. для этой статистики величина смещения равна:

$$b_m(\mathbb{D}\xi) = \frac{1}{m}\mathbb{D}\xi$$

2.3 Асимптотическая Нормальность

Это свойство говорит о том, как себя ведёт распределение статистики на больших выборках. А именно, для многих распределений характерно такое свойство:

$$\exists\{a_m\}, \{b_m\} : \frac{\hat{\theta}_m - a_m}{b_m} \xrightarrow{m \rightarrow \infty} \zeta \sim N(0, 1)$$

Оно называется *асимптотической нормальностью*. Часто выполняется более сильное свойство:

$$\sqrt{n}(\hat{\theta}_m - \theta) \xrightarrow{m \rightarrow \infty} \bar{\zeta} \sim N(0, \sigma^2(\theta))$$

Здесь $\sigma^2(\theta)$ — какое-то число зависящее от параметра θ . Оно называется *асимптотической дисперсией*. Как правило, оно определяется из ЦПТ или её аналогов. На практике, эту дисперсию можно приблизить какой-нибудь статистикой $\hat{\sigma}_m^2$.

Используя это свойство можно прикинуть, в каком интервале должен находиться наш параметр при большом m с вероятностью γ .

$$\mathbb{P}\left(\left|\frac{\sqrt{n}(\hat{\theta}_m - \theta)}{\sigma(\theta)}\right| \leq z\right) \approx \Phi(z) - \Phi(-z) = 2\Phi(z) - 1 = \gamma$$

Или:

$$\mathbb{P}\left(\left|\frac{\sqrt{n}(\hat{\theta}_m - \theta)}{\sigma(\theta)}\right| \leq z\right) = \mathbb{P}\left(\hat{\theta}_m - \frac{\sigma(\theta)z}{\sqrt{n}} \leq \theta \leq \hat{\theta}_m + \frac{\sigma(\theta)z}{\sqrt{n}}\right)$$

Множество под последним знаком вероятности называется *асимптотическим доверительным интервалом*.

Из ЦПТ следует, что выборочное среднее является асимптотически нормальной оценкой:

$$\sqrt{n}(\bar{X} - \mathbb{E}\xi) \xrightarrow{m \rightarrow \infty} \bar{\zeta} \sim N(0, \mathbb{D}\xi)$$

Выборочные квантили абсолютно-непрерывных распределений с плотностью p также являются асимптотически нормальными оценками:

$$\sqrt{n}(\bar{Q}_\alpha - Q_\alpha) \xrightarrow{m \rightarrow \infty} \bar{\zeta} \sim N\left(0, \frac{\alpha(1-\alpha)}{p(Q_\alpha)^2}\right)$$

Очевидно, такая оценка имеет смысл только когда плотность $p(Q_\alpha)$ больше нуля.

3 Сравнение Оценок

Допустим теперь, что у нас есть две оценки $\hat{\theta}_m^{(1)}$ и $\hat{\theta}_m^{(2)}$ одного и того же параметра θ . А как понять, какая лучше?

Есть множество способов решения такой задачи, но мы пока что рассмотрим только два.

3.1 Сравнение асимптотически нормальных оценок

Если оценки асимптотически нормальны, то можно рассмотреть асимптотические дисперсии.

Будем говорить, что $\hat{\theta}_m^{(1)}$ оценка *не хуже* $\hat{\theta}_m^{(2)}$, если при любом значении параметра её дисперсия меньше или равна второй дисперсии или (если знак строгий, то *лучше*):

$$\forall \theta \in \Theta : \sigma_1(\theta) \leq \sigma_2(\theta)$$

Для понимания, насколько одна статистика лучше другой, вводят параметр асимптотической эффективности.

$$e(\hat{\theta}_m^{(1)}, \hat{\theta}_m^{(2)}) := \frac{\sigma_1^2}{\sigma_2^2}$$

Смысл этого параметра можно нащупать, если сравнить асимптотические доверительные интервалы при одинаковом γ . Найдём такие n при которых величина отклонения от статистики равна:

$$\frac{\sigma_1 z}{\sqrt{n_1}} = \frac{\sigma_2 z}{\sqrt{n_2}}$$

Или:

$$e(\hat{\theta}_m^{(1)}, \hat{\theta}_m^{(2)}) = \frac{\sigma_1^2}{\sigma_2^2} = \frac{n_2}{n_1}$$

То есть, параметр показывает, во сколько раз больше нужно измерений с оценкой $\hat{\theta}_m^{(2)}$, чтобы добиться той же точности, что и с параметром $\hat{\theta}_m^{(1)}$.

3.2 Теоретическая среднеквадратичная ошибка

Если ничего не известно про асимптотическую нормальность, то для сравнения оценок рассматривают *среднеквадратичную ошибку* (Mean Squared Error) приближения параметра статистикой:

$$R := \mathbb{E}(\hat{\theta}_m - \theta)^2 = \mathbb{E}(\hat{\theta}_m - \mathbb{E}\hat{\theta}_m - b_m(\theta))^2 = \mathbb{D}\hat{\theta}_m - 2\mathbb{E}(\hat{\theta}_m - \mathbb{E}\hat{\theta}_m)\mathbb{E}b_m(\theta) + \mathbb{E}b_m^2(\theta) = \mathbb{D}\hat{\theta}_m + b_m^2(\theta)$$

Это число также называют *среднеквадратичным риском*. Очевидно, сравнение имеет смысл при одинаковых размерах выборки. Так, будем говорить, что $\hat{\theta}_m^{(1)}$ *не хуже* $\hat{\theta}_m^{(2)}$, если при любом значении параметра её среднеквадратичная ошибка меньше или равна среднеквадратичной ошибки второй оценки:

$$\forall \theta \in \Theta : R_1 \leq R_2$$

Заметим, что требование сравнения среднеквадратичного риска по всем параметрам отпадает, если мы рассматриваем оценки с одинаковым смещением. В этом случае вместо риска можно сравнивать дисперсии параметров.

1: Задача на подумать 1

В пункте 1.2 мы определили, как можно приблизить оценки параметров логнормального распределения.

- 1) Проверьте состоятельность, несмещённость и асимптотическую нормальность.
- 2) Найдите среднеквадратичный риск для этих параметров.

2: Задача на подумать 2

Допустим, мы моделируем число коммитов в день/неделю/месяц. Для достаточно крупных постоянно разрабатываемых проектов можно попробовать использовать распределение Пуассона. Однако, нам необходимо оценить параметр этого распределения. Здесь предложены три варианта:

$$1) \hat{\theta}_m^{(1)} = \bar{X}$$

$$2) \hat{\theta}_m^{(1)} = \text{med}(X)$$

$$3) \hat{\theta}_m^{(1)} = S^2$$

- 1) Проверьте состоятельность, несмещённость и асимптотическую нормальность.
- 2) Найдите среднеквадратичный риск для этих параметров.
- 3) Сравните оценки, какая лучше?
- 4) Оцените параметр распределения по [данным](#) одного маленького проекта.
- 5) Альтернативный [репозиторий](#) для предыдущего задания.