

Домашнее Задание 8-9

...самая мякотка из мякотки; прям во рту тает...

Трепещите! Вышмат на практически всех направлениях во многих ВУЗах нужен именно для понимания работы следующих механизмов, которые позволили математизировать почти каждую современную науку.

Биология, химия, физика, медицина... Да даже лингвистика и филология! Везде, где возникают эксперименты и числа, качество эксперимента и выводы строятся на следующих статистических тестах. Но об этом подробнее чуть ниже. Это база. Это основа. Это фундамент прикладной статистики. Так что спрос на знание этих критериев будет самым строгим.

1 Гипотезы согласия и однородности

Начнём с упрощённого примера. Бигфарма проплатила Вам изучение нового модного препарата «Фуфломецин-Максимум», который в теории должен невероятно эффективно лечить простудные заболевания. Есть две случайные выборки людей. Одних лечили «Фуфломецином». Другим давали пустышку. Смотрели на срок выздоровления пациентов. Итого у нас две выборки: срок выздоровления пациентов принимавших «Фуфломецин» и, соответственно, срок выздоровления не принимавших.

У любознательного читателя может возникнуть один из следующих вопросов. Как понять, сократил ли наш «Фуфломецин» срок выздоровления пациента? Распределена ли выборка пациентов, принимавших «Фуфломецин» нормально? А если нет? Быть может согласно Пуассону? ~~Какова цель моего существования? Зачем я читаю эту графоманию?~~

Давайте попробуем наши вопросы формально записать. Допустим у нас есть две выборки $X = (X_i)_{i=1}^m \sim \xi$ и $Y = (Y_j)_{j=1}^n \sim \zeta$.

Если нас интересует, равны ли распределения генеральных совокупностей ξ и ζ , то такой вопрос называют *гипотезой однородности*.

Если же нас интересует, распределена ли выборка согласно какому-то конкретному известному закону $\tilde{\xi}$, то это называется *гипотезой согласия*.

Так, проверив гипотезу однородности на двух выборках можно сказать, если значимая разница между сроком выздоровления у пациентов, принимающих «Фуфломецин», и пациентов, принимающих пустышку.

А если мы захотим узнать, распределено ли время выздоровления нормально с конкретными параметрами, то нам нужно проверять гипотезу согласия.

1.1 Нормальные выборки

Для начала рассмотрим обе гипотезы для нормального распределения. Или: $X \sim N(a_1, \sigma_1^2)$, $X \sim N(a_2, \sigma_2^2)$.

Оно стоит особняком, так как известно, что для равенства нормальных распределений необходимо и достаточно равенство соответствующих параметров. Более того, нам даже известно распределение для этих параметров.

Так, для проверки гипотезы согласия нам нужно всего лишь проверить равенство дисперсии

и матожидания заданным значениям. Соответствующие тесты разбирались на предыдущем занятии (всё есть в предыдущей домашке).

Для проверки однородности всё гораздо интереснее. Нужно проверить равенство матожиданий и дисперсий соответственно и, если для первого известен двухвыборочный тест Стьюдента (см. предыдущую домашку), то для дисперсий нужен новый тест. Благо, их есть у меня.

1.1.1 Двухвыборочный F-тест Фишера

Нулевая гипотеза — равенство дисперсий:

$$H_0 : \sigma_1^2 = \sigma_2^2$$

В качестве альтернативы можно рассматривать одну из двух гипотез:

$$(a) H_1 : \sigma_1^2 \neq \sigma_2^2$$

$$(b) H_1 : \sigma_1^2 > \sigma_2^2$$

Статистика довольно проста и следует из определения распределения Фишера:

$$T = \frac{\tilde{s}_X^2}{\tilde{s}_Y^2} \sim \mathbf{F}(m-1, n-1)$$

Напоминаю, что тут $\tilde{s}^2$ — исправленная выборочная дисперсия. Соответственно, критические области будут следующие:

$$(a): (-\infty, f_{\frac{\alpha}{2}}) \cup (f_{1-\frac{\alpha}{2}}, \infty)$$

$$(b): (f_{1-\alpha}, \infty)$$

Тут f_γ — квантиль уровня γ распределения Фишера со степенями свободы (параметрами) $n-1$ и $m-1$.

1.2 Критерии Уилкоксона и Манна-Уитни

В случае, если выборки распределены не нормально задача становится сложнее. Давайте ослабим условия. Пусть наше распределение непрерывное. На практике это означает то, что среди реализаций выборки нет повторяющихся значений. За стенами аудитории, как правило именно такие данные.

Если это условие чуть-чуть нарушается, то это не страшно. Для этого есть, так называемые поправки. Однако за одним исключением немного ниже, мы пропустим это болото, так как поправок довольно много на все случаи жизни.

Для начала познакомимся с так называемыми *ранговыми критериями однородности*. Вердикт о равенстве распределений в них выносится на основе *рангов* — порядковых номеров элементов в объединённой выборке.

Нулевая гипотеза будет следующей:

$$H_0 : F_\xi = F_\zeta$$

Против одной из трёх альтернатив:

$$(a) H_1 : F_\xi \neq F_\zeta$$

$$(b) H_1 : F_\xi > F_\zeta$$

$$(c) H_1 : F_\xi < F_\zeta$$

Для них статистика строиться по следующему алгоритму:

1. Объединим две выборки в одну, где какой элемент был изначально.
2. Выбираем одну из выборок (как правило ту, где элементов меньше) и выписываем порядковые номера элементов выбранной выборки в вариационном ряду составленном из элементов двух выборок.
3. Считаем статистику, как сумму номеров выписанных на предыдущем шаге.

$$W = \sum_{i=1}^m r_i$$

Заметим (вспомнив комбинаторику), что $W_{min} = \frac{m(m+1)}{2}$, а $W_{max} = nm + \frac{m(m+1)}{2}$. Распределение статистики при выполнении нулевой гипотезы известно и протабулировано. А ещё, оно симметрично относительно центра интервала $W_c = \frac{W_{max} + W_{min}}{2}$. Поэтому $W_{1-\alpha} = 2W_c - W_\alpha = W_{max} + W_{min} - W_\alpha$. Так, критические области будут следующими:

$$(a) : [W_{min}, W_{\frac{\alpha}{2}})(W_{1-\frac{\alpha}{2}}, W_{max}]$$

$$(b)(W_{1-\alpha}, W_{max}]$$

$$(c)[W_{min}, W_\alpha)$$

Тут W_α — квантиль распределения Вилкоксона. При большом количестве элементов выборки обычно статистику приводят к нормальной:

$$\tilde{W} = \frac{W - W_c}{\sqrt{DW}} \sim N(0, 1)$$

$$DW = \frac{mn(m+n+1)}{12}$$

Тут я продемонстрирую как обычно работают поправки на повторы. Если в тестах предполагающих непрерывность распределения встречаются повторные наблюдения, то их иногда можно тоже учитывать. В основном это касается случаев достаточно больших выборок.

Итак, в наших больших выборках ($n, m > 50$) есть несколько (< 5) повторных наблюдений. Как правило, делают следующее: просто при подсчёте ранга всем повторным наблюдениям

приписывают средний ранг. Такое множество одинаковых измерений называют связкой. Пусть, g — число связок, а t_k — число одинаковых наблюдений в связке.

Поправка заключается в исправлении дисперсии при предельном переходе к нормальному распределению, а именно:

$$DW^* = \frac{mn}{12} \left((m+n-1) - \frac{\sum_{k=1}^g t_k(t_k^2-1)}{(m+n)(m+n+1)} \right)$$

Есть ещё ранговый тест Манна-Уитни. Так как его статистика сводится к статистике Вилкоксона, то я не стану подробно на нём останавливаться. Можете про него почитать в соответствующей литературе.

$$U = W - \frac{m(m+1)}{2}$$

1.3 Критерий Колмогорова

Другой критерий основан на сравнении функций распределения двух выборок. Тут уже есть два варианта: для гипотезы однородности и гипотезы согласия.

Интересно, что в обоих случаях математическая сторона теста одинакова. За исключением того, что в одном случае у нас есть известный закон и его функция распределения, а в другом лишь её приближение в виде эмпирической функции распределения. Обобщенно гипотезы запишем так:

$$H_0 : F_\xi = F_\zeta$$

$$H_1 : F_\xi \neq F_\zeta$$

Статистика теста — наибольшая возможная разница между двумя функциями распределения:

$$D = \sup_{x \in \mathbb{R}} |F_\xi(x) - F_\zeta(x)|$$

При больших размерах выборок ($m, n > 50$), статистика распределена согласно протабулированному распределению Колмогорова. Критическая область следующая:

$$(k_{1-\alpha}, \infty)$$

Тут k_α — квантиль распределения Колмогорова. А теперь поконкретнее поговорим, как на практике обчислять эти статистики.

Для гипотезы согласия обычно используется следующая формула:

$$D(X_m) = \max_{1 \leq i \leq m} \left[\frac{i}{m} - F_\zeta(X_{(i)}), F_\zeta(X_{(i)}) - \frac{i-1}{m} \right]$$

Тут F_ζ — функция распределения известного закона. Для гипотезы однородности статистика считается похожим образом:

$$D_X(X_m) = \max_{1 \leq i \leq m} \left[\frac{i}{m} - \bar{F}_\zeta(X_{(i)}), \bar{F}_\zeta(X_{(i)}) - \frac{i-1}{m} \right]$$

$$D_Y(Y_n) = \max_{1 \leq j \leq n} \left[\frac{j}{n} - \bar{F}_\xi(Y_{(j)}), \bar{F}_\xi(Y_{(j)}) - \frac{j-1}{n} \right]$$

$$D = \max(D_X, D_Y)$$

Тут $\bar{F}_\xi$ и $\bar{F}_\zeta$ — эмпирические функции распределения соответствующих выборок.

1.4 Критерий χ^2

Универсальный критерий согласия (правда работающий только для больших выборок) носит имя Пирсона. Гипотезы те же (Распределение ζ в точности известно):

$$H_0 : F_\xi = F_\zeta$$

$$H_1 : F_\xi \neq F_\zeta$$

Чтобы построить статистику разобьём ось на непересекающиеся отрезки (аналогично тому, как строим гистограмму):

$$-\infty < a_0 < a_1 < \dots < a_r < \infty$$

И посмотрим, как отличается гистограмма от теоретического распределения. Пусть $p_i = \mathbb{P}(a_{i-1}, a_i]$. А n_i — число значений выборки на том же отрезке. Рассмотрим следующую статистику:

$$X^2 = \sum_{i=1}^r \frac{(n_i - mp_i)^2}{mp_i}$$

Если гипотеза верна, то статистика распределена согласно распределению $\chi^2(r-1)$. При известном квантиле $h_{1-\alpha}$ распределения χ^2 критическая область будет выглядеть так:

$$(h_{1-\alpha}, \infty)$$

Если известно семейство распределений, но неизвестны параметры, то параметры можно оценить согласно методу максимального правдоподобия. Правда, статистика будет иметь другое число степеней свободы: $X^2 \sim \chi^2(r-l-1)$, — где l — число оцениваемых параметров.

2 Коэффициенты корреляции и критерии независимости

Чтобы не играть в сломанный телефон будет выдан отрывок из учебника. Материал для пары был подготовлен в точности по нему (как и когда-то собственно сам автор этой графомании).

1: Задача на подумать: межпространственные путешествия

Если кому-то вдруг мало лабораторной, то предлагаю подумать над следующими в ручную собранными данными.

Один преподаватель, чья личность не так уж и важна для сего повествования, иногда посещал корпус ИТМО на Ломоносова, 9. В редкие моменты просветления он даже записывал время, за которое добирался от станции Ломносовской до корпуса на улице Ломоносова!

Добирался он на метро примерно в одно и то же время по будням. И захотел он как-то узнать, а как ему будет добираться быстрее: по красной ветке через Маяковскую или по оранжевой через Александра Невского.

Данные ниже в табличке. Судя по исключительно субъективным ощущениям, red goes fasta.

Красная (мин. : с.)	32:00	29:09	34:51	33:47	32:28	36:32	32:28	28:03	29:56
Оранжевая (мин. : с.)	32:42	33:15	38:29	31:07	37:19	28:49			