

Домашнее Задание 10-11

...конец содержательной части утопленный в приложениях...

1 Однофакторный Анализ

Чтобы понять, как работает однофакторный анализ представим следующую ситуацию. Есть программа которая в среднем решает какую-то одну задачу за определённое время. Предположим, по итогу тестирования у нас есть n результатов работы программы. Не умаляя общности (вопрос к аудитории: почему?), конкретный тест мы можем моделировать следующим образом:

$$X_i = \mu + \varepsilon_i$$

Где ε_i — случайная величина имеющая одинаковое распределение и нулевое матожидание.

Теперь, положим, мы изменим нашу программу. Как проверить изменилось ли среднее время? А если мы сделаем это несколько раз? Можно последовательно при каждом измерении попарно сравнивать что было и что стало. Но что если изменения в каждой паре будут очень маленькими? Тогда может случиться такая ситуация, когда после большого числа изменений программы изменения между первой и последней версиями накопятся и будут критическими. Можно проверять гипотезу однородности попарно на каждой паре имеющихся выборок. Такой подход однако будет очень затратным (посчитайте, сколько раз нужно будет проверить гипотезу однородности).

Для решения этой задачи используется следующий подход. Соберём все измерения в одну таблицу:

1	2	...	k
X_{11}	X_{21}	...	X_{k1}
...	...	...	...
X_{1n_1}	X_{2n_2}	...	X_{kn_k}

Тут первый индекс отвечает за номер модификации. А второе — номер измерения при данной модификации. Обозначим общее число измерений так: $n := n_1 + n_2 + \dots + n_k$. Каждое измерение будем моделировать случайной величиной, раскладываемой следующим образом:

$$X_{ij} = \mu + \tau_i + \varepsilon_{ij}$$

Тут μ — какое-то абстрактное общее среднее. Например:

$$\mu := \mathbb{E} \left(\frac{1}{n} \sum_{i,j} X_{ij} \right)$$

Число τ_i — относительный вклад модификации i . Важно чтобы относительные вклады компенсировали друг друга: $\sum \tau_i = 0$. Например, его можно выбрать так:

$$\tau_i := \mathbb{E} \left(\frac{1}{n} \sum_j X_{ij} \right) - \frac{\mu}{k}$$

Ключевое предположение: характер поведения остатков ε_{ij} . В нашей модели случайность обеспечивается случайной величиной ε_{ij} . Далее мы будем предполагать, что все ε_{ij} имеют нулевое ожидание, одинаково распределены и взаимно-независимы.

Нулевая гипотеза, которую мы будем рассматривать будет заключаться в следующем: ни одна модификация не вносит весомый вклад в модель:

$$H_0 : \forall i, j : \tau_i = \tau_j$$

Альтернатива: отрицание нулевой гипотезы — где-то что-то отличается:

$$H_1 : \exists i, j : \tau_i \neq \tau_j$$

1.1 Критерий Краскелла-Уоллиса

Для проверки этой гипотезы можно использовать ранговый критерий Краскелла-Уоллиса.

Статистика строится следующим образом. Сначала считаем ранги элементов r_{ij} в объединённой выборке $X_1, X_2, \dots, X_k$ как для статистики Вилкоксона. Статистика следующая.

$$H = \frac{12}{n(n+1)} \sum_{j=1}^k (\bar{R}_j - \bar{R})^2$$

Тут $\bar{R}_j$ — средний ранг элементов j -ой модификации.

$$\bar{R}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} r_{ij}$$

$\bar{R}$ — средний ранг по объединённой выборке.

$$\bar{R} = \frac{1}{n} \sum_{ij} r_{ij} = \frac{n+1}{2}$$

При $\min(n_1, n_2, \dots, n_k) \rightarrow \infty$ статистика подчиняется распределению χ^2 . Почему это так, а не иначе можете почитать в оригинальной статье: Kruskal; Wallis (1952). "Use of ranks in one-criterion variance analysis (она не такая уж и сложная).

2 Дисперсионный анализ

Если дополнительно известно, что все измерения принадлежат выборкам распределённым нормально, то задачу однофакторного анализа называют задачей дисперсионного анализа.

В этом случае удобнее использовать следующую модель:

$$X_{ij} = a_i + \varepsilon_{ij}$$

Тут a_i — число. Оно имеет смысл, как абстрактное среднее для фиксированной i -ой модификации. ε_{ij} — случайная величина имеющая тот же смысл, однако накладывается дополнительное условие: остатки распределены нормально:

$$\exists \sigma^2 > 0; \forall i, j : \varepsilon_{ij} \sim \mathbf{N}(0, \sigma^2)$$

Обычно, выполнимость предположений модели обуславливается дизайном эксперимента. В случае сомнений, равенство дисперсий у остатков можно проверить при помощи теста Бартлетта ($H_0 : \forall i, j : \sigma_i^2 = \sigma_j^2$). Разбор этого теста выходит за рамки нашего курса, поэтому мы галантно пройдем мимо.

2.1 Тест Фишера

Для проверки гипотезы дисперсионного анализа часто используют тест Фишера. В нём используется следующая статистика:

$$F = \frac{SS^{ex} \cdot (n - k)}{SS^{in} \cdot (k - 1)} \sim \mathbf{F}(k - 1, n - k)$$

Тут SS^{in} — внутригрупповая дисперсия. Если за среднее выборки соответствующей одной модификации положить $\bar{X}_i$, то внутригрупповая дисперсия считается следующим следующим образом (это средневзвешенная арифметическая групповых дисперсий):

$$SS^{in} = \frac{1}{n - k} \sum_{i,j} (X_{ij} - \bar{X}_i)^2$$

SS^{ex} — межгрупповая дисперсия. Считается она так (дисперсия групповых средних относительно общей средней):

$$SS^{ex} = \sum_j \frac{n_j}{k - 1} (\bar{X}_j - \bar{X})^2$$

3 Регрессия

Опять же, тут практик не успевает написать, да и не хочет играть в сломанный телефон. Будет предложена для ознакомления глава из учебника, откуда, собственно, сам материал и брался с минимальными косметическими изменениями.

Вместо задачек предлагается подумать подробнее о лабораторных!