

§ 10. КОЭФФИЦИЕНТЫ РАНГОВОЙ КОРРЕЛЯЦИИ СПИРМЕНА И КЕНДЕЛЛА

Рассматриваемые в этом параграфе коэффициенты вычисляются только для порядковых шкал.

Определение 10.1. Шкалы, в которых существенен лишь взаимный порядок, в котором следуют результаты измерений, а не их количественные значения, называют порядковыми или ординальными шкалами.

Пусть имеется два признака A и B , между которыми мы хотим установить наличие зависимости или независимости. Пусть $(X_1, \dots, X_n)$ — измерение степени выраженности признака A , $(Y_1, \dots, Y_n)$ — измерение степени выраженности признака B . Каждый объект характеризует пара (X_i, Y_j) , $1 \leq i \leq n$, $1 \leq j \leq n$.

Коэффициент ранговой корреляции Спирмена

Проранжируем наблюдения $X_1, \dots, X_n$ и $Y_1, \dots, Y_n$, ранги которых будут соответственно обозначаться $r_1, \dots, r_n$ и $s_1, \dots, s_n$, то есть r_i — номер наблюдения X_i в вариационном ряду, построенном по наблюдениям $X_1, \dots, X_n$. Аналогично s_i — номер наблюдения Y_i в вариационном ряду, построенном по наблюдениям $Y_1, \dots, Y_n$. Будем предполагать, что в выборках нет повторяющихся элементов.

Рассмотрим статистику Спирмена $S = \sum_{i=1}^n (s_i - r_i)^2$. Вычислим коэффициент ранговой корреляции Спирмена:

$$\rho = 1 - \frac{6S}{n^3 - n}.$$

Нетрудно показать, что $|\rho| \leq 1$. Если $|\rho| = 1$, то это означает полную зависимость одного признака от другого, либо, иначе говоря, полную предсказуемость одной выборки по другой. Если ранги признаков совпадают, то $\rho = 1$. Если последовательности рангов полностью противоположны, то $\rho = -1$. Оба случая означают полную предсказуемость одной ранговой последовательности по другой, или, другими словами, полную зависимость признаков A и B .

Сформулируем гипотезы:

- H_0 : признаки A и B взаимно независимы.
- H_1 : имеется монотонная положительная связь признаков.
- H'_1 : имеется монотонная отрицательная связь признаков.
- H''_1 : имеется монотонная связь признаков.

Гипотеза H_0 соответствует отсутствию взаимосвязи между признаками или, иначе говоря, независимости признаков. Если гипотеза H_0 справедлива, то распределение статистики ρ симметрично и концентрируется около нуля. При наличии зависимости распределение окажется другим. Для монотонной положительной зависимости распределение ρ сдвинуто вправо, для монотонной отрицательной — влево.

Для проверки гипотезы H_0 необходимо обратиться к таблицам распределения коэффициента Спирмена [3], вычисленным в предположении истинности гипотезы H_0 . По заданной вероятности ошибки первого рода α необходимо найти соответствующие пороговые значения, после чего при попадании вычисленного по наблюдениям коэффициента ρ в критическую область следует отклонить гипотезу H_0 в пользу альтернативной гипотезы. При выборе в качестве альтернативы гипотезы H_1 (положительная монотонная связь) критическую область следует выбрать в виде: $(c_1, 1]$. При выборе альтернативы гипотезы H'_1 (отрицательная монотонная связь) критическую область следует выбрать в виде: $[-1, c_2)$. При выборе альтернативной гипотезы H''_1 критическая область для гипотезы H_0 имеет вид: $[-1, c_3) \cup (c_4, 1]$. Пороговые значения c_1, c_2, c_3, c_4 определяются из статистических таблиц так, чтобы вероятность попадания в критическую область при выполнении гипотезы H_0 была равна α .

Коэффициент ранговой корреляции Кенделла

Коэффициент ранговой корреляции Кенделла применяется для решения тех же задач, что и коэффициент Спирмена. Проверяются те же гипотезы, и алгоритм проверки такой же, как и при использовании коэффициента Спирмена. Разница лишь в том, что используются статистические таблицы

для распределения коэффициента Кендалла [3]. Для вычисления статистики Кендалла достаточно посчитать количество инверсий (минимальное число перестановок соседних объектов), которое надо сделать для того, чтобы одно упорядочение объектов превратилось в другое.

Пусть есть пары наблюдений каждого из признаков $(X_1, Y_1), \dots, (X_n, Y_n)$. Упорядочим наблюдения первого признака и пронанжируем их рангами от 1 до n . Затем ранжируем последовательность наблюдений второго признака, при этом объекты перенумерованы в соответствии с рангами первой совокупности. Пусть во втором наборе приписаны каждому наблюдению ранги $z_1, \dots, z_n$, то есть теперь все объекты характеризуются парами рангов: $(1, z_1), \dots, (n, z_n)$. После перенумерования ранги измерений признаков A представляют собой новые номера самих объектов. Пусть R — число инверсий в выборке $\{z_1, \dots, z_n\}$. Инверсия — нарушение порядка. Например, в ряду $(4, 3, 1, 2)$ имеется всего 5 инверсий.

Рассмотрим коэффициент ранговой корреляции Кендалла:

$$\tau = 1 - \frac{4R}{n(n-1)}.$$

Нетрудно доказать, что $|\tau| \leq 1$. При этом $|\tau| = 1$ означает полную предсказуемость (зависимость) признаков. При больших n при справедливости гипотезы H_0 случайные величины $\sqrt{n-1}\rho$ и $\tau\sqrt{9n(n+1)/(2(2n+5))}$ приближенно распределены по стандартному нормальному закону $N(0, 1)$, что позволяет проверять гипотезу H_0 , пользуясь указанной асимптотикой.

Для обоих коэффициентов корреляции характерно то обстоятельство, что они обнаруживают лишь монотонную зависимость признаков.

§ 11. КОЭФФИЦИЕНТ КОРРЕЛЯЦИИ ПИРСОНА

Коэффициент корреляции Пирсона применяется к данным, измеренным в шкале отношений.

Определение 11.1. Шкалой отношений называют такую шкалу с непрерывным множеством числовых значений, в которой

о двух сопоставляемых объектах можно сказать не только, одинаковы они или различны, не только, в каком из них признак выражен сильнее, но и во сколько раз сильнее этот признак выражен.

Предположим, что есть генеральная совокупность, каждый элемент которой обладает двумя количественными признаками. Если случайным образом извлекать объекты, то пусть ξ — значение, которое принимает первый признак, η — значение, которое принимает второй признак. Величины ξ и η — случайные. Корреляция случайных величин ξ и η выражается следующей формулой:

$$\rho(\xi, \eta) = \frac{\text{cov}(\xi, \eta)}{\sqrt{D\xi}\sqrt{D\eta}}.$$

Если случайные величины ξ и η независимы, то корреляция равна нулю. Обратное утверждение, вообще говоря, неверно. Если $\rho = 1$, то существует положительная линейная связь между величинами ξ и η такая, что $\eta = a + b\xi$, $b > 0$. Если $\rho = -1$, то существует линейная связь между величинами ξ и η такая, что $\eta = a + b\xi$, $b < 0$. Если вектор $(\xi, \eta)^T$ подчиняется совместному нормальному распределению с вектором математических ожиданий $a = (a_1, a_2)^T$ и ковариационной матрицей

$$\begin{pmatrix} \sigma_1^2 & \sigma_1\sigma_2\rho \\ \sigma_1\sigma_2\rho & \sigma_2^2 \end{pmatrix},$$

то корреляция случайных величин ξ и η равна нулю тогда и только тогда, когда эти случайные величины взаимно независимы, $\sigma_1^2 = D\xi$, $\sigma_2^2 = D\eta$.

Получим оценку коэффициента корреляции — выборочный коэффициент корреляции Пирсона, который определяется выражением:

$$r_{X,Y} = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{s_X s_Y},$$

где $s_X^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$, $s_Y^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2$. Здесь предполагается, что задана двумерная выборка: $(X_1, Y_1), \dots, (X_n, Y_n)$. Совместное распределение случайных величин ξ и η является нормальным.

Сформулируем гипотезы:

- $H_0: \rho = 0$ — гипотеза о независимости.
- $H_1: \rho > 0$.
- $H'_1: \rho < 0$.
- $H''_1: \rho \neq 0$ — двусторонняя альтернатива.

Справедливо утверждение. При сделанных предположениях о распределении случайного вектора $(\xi, \eta)^T$, статистика

$$t = r_{X,Y} \sqrt{n-2} / \sqrt{1-r^2} \quad (11.1)$$

при выполнении гипотезы H_0 подчиняется распределению Стьюдента с $n-2$ степенями свободы.

При использовании статистики (11.1) для альтернативы H_1 критическая область для гипотезы H_0 имеет вид: $S = (t_{1-\alpha, n-2}, \infty)$, для альтернативы H'_1 критическая область для гипотезы H_0 имеет вид: $S = (-\infty, t_{\alpha, n-2})$. Критическая область для нулевой гипотезы H_0 при альтернативе H''_1 будет иметь вид:

$$S = (-\infty, t_{\frac{\alpha}{2}, n-2}) \cup (t_{1-\frac{\alpha}{2}, n-2}, +\infty),$$

где $t_{\beta, n-2}$ — квантиль уровня β распределения Стьюдента с $n-2$ степенями свободы. Если значение статистики $t \in S$, то гипотеза H_0 отклоняется, если $t \notin S$, то гипотеза H_0 принимается. Величина вероятности ошибки первого рода равна α .

§ 12. КРИТЕРИЙ СОГЛАСИЯ ХИ-КВАДРАТ ДЛЯ СЛОЖНЫХ ГИПОТЕЗ

В критерии согласия хи-квадрат реализуется следующая схема. Выдвигаются гипотезы:

- $H_0: F_\xi(x) \equiv F(x)$ — нулевая гипотеза.
- $H_1: F_\xi(x) \neq F(x)$ — альтернативная гипотеза.

В прикладных задачах, как правило, известна не сама функция распределения, а параметрическое семейство, которому