

РЕГРЕССИОННЫЙ АНАЛИЗ

§ 1. СПЕЦИФИКАЦИЯ МОДЕЛИ

В главе будет рассматриваться следующая модель наблюдений, связывающая значения некоторого наблюдаемого показателя y и объясняющих переменных $x = (x_1, \dots, x_k)^T$:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i, \quad i = 1, \dots, n, \quad (1.1)$$

где $\beta^T = (\beta_0, \dots, \beta_k)$ — неизвестные параметры; x_{ij} — значения объясняющих факторов; ε_i — ненаблюдаемая случайная компонента; j — номер переменной; i — номер наблюдения.

Будем предполагать, что имеется n наблюдений (измерений) показателя y_i , точно известны значения объясняющих переменных $x_i = (x_{i1}, \dots, x_{ik})$ в каждом из наблюдений, причем в модель наблюдений (1.1) входит значение ненаблюдаемой случайной компоненты ε_i . Ненаблюдаемая компонента может представлять собой ошибку измерений или заменять совокупное действие других переменных, значения которых не учитываются в модели наблюдений (1.1).

Сформулируем основные предположения регрессионного анализа, которые относятся к случайным компонентам ε_i , $i = 1, \dots, n$.

Первая группа предположений:

- Случайные величины ε_i , $i = 1, \dots, n$ образуют так называемый слабый белый шум, т.е. последовательность центрированных ($E\varepsilon_i = 0$, $i = 1, \dots, n$) и некоррелированных ($E(\varepsilon_l \varepsilon_u) = 0$ при $l \neq u$) случайных величин с одинаковыми дисперсиями σ^2 ($E\varepsilon_i^2 = \sigma^2$, $i = 1, \dots, n$).

Кроме первой группы предположений будем также рассматривать вторую группу, в которой сформулируем предположение о совместном распределении случайных величин ε_i , $i = 1, \dots, n$.

Вторая группа предположений:

- Совместное распределение случайных величин ε_i , $i = 1, \dots, n$ является нормальным распределением с нулевым вектором математических ожиданий и ковариационной матрицей $\sigma^2 E_n$, т.е. случайный вектор $\varepsilon^T = (\varepsilon_1, \dots, \varepsilon_n) \sim N(0, \sigma^2 E_n)$, где E_n — единичная матрица порядка $n \times n$.

Иногда рассматривается частный случай модели (1.1), в которой априори полагают $\beta_0 = 0$. Конечно, рассмотрение такого частного случая требует отдельного обоснования.

Модель наблюдений (1.1) можно записать в матричном виде:

$$Y = X\beta + \varepsilon, \quad (1.2)$$

где $Y = (y_1, \dots, y_n)^T$, $\beta = (\beta_0, \beta_1, \dots, \beta_k)^T$, $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)^T$,

$$X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix}$$

— матрица порядка $n \times (k + 1)$.

§ 2. МЕТОД НАИМЕНЬШИХ КВАДРАТОВ

В модели наблюдений (1.1), (1.2) неизвестными являются параметры $\sigma, \beta_0, \beta_1, \dots, \beta_k$. Рассмотрим в качестве процедуры оценивания неизвестных параметров метод наименьших квадратов. Метод наименьших квадратов удобнее всего излагать геометрически — на языке векторов. С этой целью введем обозначение: $X_r = (x_{1r}, x_{2r}, \dots, x_{nr})^T$, $r = 1, \dots, k$ — столбец матрицы X , тогда

$$X = (X_0, X_1, \dots, X_k),$$

где $X_0 = (1, 1, \dots, 1)^T$.

Из смысла задачи оценки неизвестных параметров β следует, что оценки разумно выбирать так, чтобы вектор $X\beta$ как можно «лучше» объяснял бы значения наблюдаемого показателя, т.е. вектор Y . Но тогда естественно выбирать β , минимизируя расстояние между векторами или квадрат длины отклонения $Y - X\beta$.

В этом случае в качестве минимизируемого критерия рассматривают

$$(Y - X\beta)^T(Y - X\beta) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_k x_{ik})^2. \quad (2.1)$$

Оценки, получаемые из условия минимума (2.1), называют оценками метода наименьших квадратов. Разумеется, для нахождения оценок β могут быть применены совсем другие процедуры, например, вместо суммы квадратов можно было бы брать сумму абсолютных величин разностей.

Для минимизации выражения (2.1) по неизвестным параметрам β воспользуемся геометрическими представлениями. Рассмотрим в n -мерном пространстве $\mathbb{R}^n$ линейное подпространство $L(X_0, X_1, \dots, X_k)$, в котором вектора $X_0, X_1, \dots, X_k$ являются базисом. При этом, конечно, в дальнейшем будем предполагать, что они линейно независимы. Пусть $\hat{Y}$ представляют собой ортогональную проекцию вектора Y на подпространство $L(X_0, X_1, \dots, X_k)$. Очевидно, что для любого другого вектора $\tilde{Y} \in L(X_0, \dots, X_k)$ будет выполняться

$$(Y - \hat{Y})^T(Y - \hat{Y}) \leq (Y - \tilde{Y})^T(Y - \tilde{Y}),$$

неравенство следует из условия ортогональности вектора $Y - \hat{Y}$ подпространству $L(X_0, \dots, X_k)$, действительно, для любого вектора $\tilde{Y} \in L(X_0, \dots, X_k)$ выполняется $(\tilde{Y} - \hat{Y}) \perp (Y - \hat{Y})$, так как $(\tilde{Y} - \hat{Y}) \in L(X_0, \dots, X_k)$ и $(Y - \hat{Y}) \perp L(X_0, \dots, X_k)$. Но тогда

$$\begin{aligned} (Y - \tilde{Y})^T(Y - \tilde{Y}) &= \\ &= (Y - \hat{Y} - (\tilde{Y} - \hat{Y}))^T(Y - \hat{Y} - (\tilde{Y} - \hat{Y})) = \\ &= (Y - \hat{Y})^T(Y - \hat{Y}) + (\tilde{Y} - \hat{Y})^T(\tilde{Y} - \hat{Y}), \end{aligned}$$

откуда следует

$$(Y - \tilde{Y})^T(Y - \tilde{Y}) \geq (Y - \hat{Y})^T(Y - \hat{Y}),$$

причем равенство возможно, только если $\tilde{Y} = \hat{Y}$. Для того, чтобы вектор $Y - \hat{Y}$ был ортогонален подпространству $L(X_0, X_1, \dots, X_k)$, необходимо и достаточно, чтобы

$$(Y - \hat{Y}) \perp X_i, \quad i = 0, 1, \dots, k$$

или, чтобы

$$(Y - \hat{Y})^T X = 0. \quad (2.2)$$

Так как вектор $\hat{Y} \in L(X_0, X_1, \dots, X_k)$, то существует набор коэффициентов, обозначим их через $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k$, что

$$\hat{Y} = \sum_{r=0}^k \hat{\beta}_r X_r = X\hat{\beta},$$

где $\hat{\beta} = (\hat{\beta}_0, \dots, \hat{\beta}_k)^T$. Тогда равенство (2.2) равносильно равенству

$$X^T Y - X^T X \hat{\beta} = 0$$

или равенству

$$(X^T X) \hat{\beta} = X^T Y. \quad (2.3)$$

Так как, по нашему предположению, столбцы матрицы X линейно независимы, то отсюда следует, что $n \geq k + 1$ и определитель $|X^T X| \neq 0$. Следовательно, оценки метода наименьших квадратов $\hat{\beta}$ неизвестных параметров β имеют вид:

$$\hat{\beta} = (X^T X)^{-1} X^T Y. \quad (2.4)$$

Для удобства дальнейших преобразований введем ряд новых матриц и изучим их свойства. Из формулы (2.4) следует, что ортогональная проекция произвольного вектора Y на $L(X_0, \dots, X_K)$ имеет вид $\hat{Y} = X\hat{\beta} = X(X^T X)^{-1} X^T Y$, но тогда матрица

$$P = X(X^T X)^{-1} X^T$$

представляет собой матрицу ортогонального проектирования на пространство $L(X_0, \dots, X_k)$. Рассмотрим подпространство $L^\perp$ ортогональное подпространству $L(X_0, \dots, X_k)$. Любой вектор Y из $\mathbb{R}^n$ однозначно представим в виде:

$$Y = \hat{Y} + (Y - \hat{Y}),$$

где $\hat{Y} \in L(X_0, \dots, X_k)$, $Y - \hat{Y} \in L^\perp$. Из предыдущего ясно, что

$$Y - \hat{Y} = Y - X(X^T X)^{-1} X^T Y = (E_n - X(X^T X)^{-1} X^T)Y.$$

Следовательно, матрица

$$P^\perp = E_n - P$$

является матрицей ортогонального проектирования на подпространство $L^\perp$. Действительно, для любого вектора $Y \in \mathbb{R}^n$ получаем

$$P^\perp Y = Y - PY = Y - \hat{Y},$$

но вектор $Y - \hat{Y} \perp L(X_0, \dots, X_k)$, следовательно, вектор $Y - \hat{Y} \in L^\perp$.

Нетрудно проверить справедливость следующих свойств:

1. $P^T = P$, $(P^\perp)^T = P^\perp$.
2. $P^2 = P$, $(P^\perp)^2 = P^\perp$.
3. $PP^\perp = P^\perp P = 0$.
4. $P + P^\perp = E_n$.
5. $PX_j = X_j$, $j = 0, 1, \dots, k$, $P^\perp X_j = 0$, $j = 0, 1, \dots, k$.

Для удобства дальнейшего изложения введем вектор

$$\hat{\varepsilon} = Y - \hat{Y} = P^\perp Y, \quad (2.5)$$

который, следуя сложившейся традиции, будем называть вектором остатков. Следует иметь в виду, что после нахождения коэффициентов $\hat{\beta}$ можно рассмотреть следующую функцию, которую собственно и называют линейной регрессией:

$$\hat{y}(x) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k. \quad (2.6)$$

Построенная линейная регрессия представляет собой эмпирическую зависимость между изучаемым показателем y и объясняющими переменными $x = (x_1, \dots, x_k)^T$, поэтому естественно называть остатками разности

$$y_i - \hat{y}(x_{i1}, \dots, x_{ik}) = \hat{\varepsilon}_i, \quad i = 1, \dots, n, \quad (2.7)$$

которые не объясняются построенной эмпирической моделью (2.6). Вектор, составленный из разностей $\hat{\varepsilon}_i$, и представляет собой вектор $\hat{\varepsilon} = (\hat{\varepsilon}_1, \dots, \hat{\varepsilon}_n)$.

Нетрудно заметить, что

$$\hat{\varepsilon} = P^\perp Y = P^\perp (X\beta + \varepsilon) = P^\perp \varepsilon. \quad (2.8)$$

Величины $\hat{\varepsilon}_i$, $i = 1, \dots, n$, можно, следовательно, рассматривать, как оценки ненаблюдаемых величин ε_i , $i = 1, \dots, n$.

§ 3. СВОЙСТВО ОЦЕНОК МЕТОДА НАИМЕНЬШИХ КВАДРАТОВ

Как нетрудно заметить, оценки метода наименьших квадратов обладают свойством несмещенности:

$$E\hat{\beta} = (X^T X)^{-1} X^T EY = (X^T X)^{-1} X^T X\beta = \beta.$$

Вычислим дисперсионную (ковариационную) матрицу оценок метода наименьших квадратов, считая, что выполнена первая группа предположений регрессионного анализа:

$$\begin{aligned} D\hat{\beta} &= E\{(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T\} = \\ &= E\{(X^T X)^{-1} X^T \varepsilon \varepsilon^T X (X^T X)^{-1}\} = \\ &= (X^T X)^{-1} X^T \sigma^2 E_n X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}. \end{aligned}$$

Оценки метода наименьших квадратов при условии выполнения предположений из первой группы являются наилучшими линейными несмещенными оценками. Линейность понимается в том смысле, что оценки имеют вид $\hat{\beta} = AY$, где $A = (X^T X)^{-1} X^T$ — матрица коэффициентов, т. е. речь идет о линейности по наблюдениям. Следуя общему определению

эффективности оценок, заметим, что оценки $\hat{\beta}$ являются наилучшими линейными несмещенными оценками в том смысле, что для любых других оценок $\tilde{\beta}$ вида $\tilde{\beta} = CY$, обладающих свойством несмещенности, оказывается, что разность дисперсионных матриц оценок $D\tilde{\beta} - D\hat{\beta}$ представляет собой неотрицательно определенную матрицу, т. е. для любого вектора $\gamma \in \mathbb{R}^{k+1}$ выполняется $\gamma^T(D\tilde{\beta} - D\hat{\beta})\gamma \geq 0$. Отсюда, в частности, сразу следует, что дисперсии оценок $\tilde{\beta}_i$ не меньше, чем дисперсии оценок $\hat{\beta}_i$, т. е. $D\tilde{\beta}_i \geq D\hat{\beta}_i$, $i = 0, 1, 2, \dots, k$.

Теорема 3.1 (теорема Гаусса–Маркова) Пусть выполнены все условия из первой группы предположений регрессионного анализа, тогда оценки метода наименьших квадратов $\hat{\beta}$ являются наилучшими линейными несмещенными оценками.

Доказательство. Пусть $\tilde{\beta} = CY$ — произвольные линейные несмещенные оценки вектора β . Из условия несмещенности следует

$$E\tilde{\beta} = CX\beta = \beta.$$

Так как это равенство должно выполняться для любого вектора β , то условие несмещенности равносильно матричному равенству $CX = E_{k+1}$. Введем в рассмотрение матрицу T , определяемую равенством

$$T = C - (X^T X)^{-1} X^T.$$

Как легко видеть, $TX = 0$. Очевидно, что

$$D\tilde{\beta} = E\{(\tilde{\beta} - \beta)(\tilde{\beta} - \beta)^T\} = E\{C\varepsilon\varepsilon^T C^T\} = \sigma^2 CC^T.$$

Заметим, что

$$\begin{aligned} CC^T &= (T + (X^T X)^{-1} X^T)(T + (X^T X)^{-1} X^T)^T = \\ &= TT^T + (X^T X)^{-1}. \end{aligned}$$

Но тогда для произвольного вектора $\gamma \in \mathbb{R}^{k+1}$:

$$\gamma^T(D\tilde{\beta} - D\beta)\gamma = \sigma^2 \gamma^T TT^T \gamma = \sigma^2 (\gamma^T T)(\gamma^T T)^T \geq 0.$$

■

Оценим дисперсию одиночного наблюдения σ^2 . Для этого вначале найдем дисперсионную (ковариационную) матрицу $D\hat{\varepsilon}$. Как следует из формулы (2.4) предыдущего параграфа:

$$D\hat{\varepsilon} = E\{P^\perp \varepsilon \varepsilon^T P^\perp\} = \sigma^2 P^\perp.$$

Рассмотрим сумму квадратов:

$$\sum_{i=1}^n \hat{\varepsilon}_i^2 = \hat{\varepsilon}^T \hat{\varepsilon} = \text{tr}\{\hat{\varepsilon} \hat{\varepsilon}^T\}.$$

Вычислим математическое ожидание:

$$E\hat{\varepsilon}^T \hat{\varepsilon} = E\text{tr}\{\hat{\varepsilon} \hat{\varepsilon}^T\} = \text{tr} E\{\hat{\varepsilon} \hat{\varepsilon}^T\} = \text{tr}\{E(P^\perp \varepsilon \varepsilon^T P^\perp)\} = \sigma^2 \text{tr} P^\perp.$$

Заметим, что

$$\begin{aligned} \text{tr} P^\perp &= \text{tr}\{E_n - X(X^T X)^{-1} X^T\} = \\ &= n - \text{tr}\{X(X^T X)^{-1} X^T\} = \\ &= n - \text{tr}\{(X^T X)(X^T X)^{-1}\} = n - k - 1. \end{aligned}$$

При выводе формулы мы воспользовались свойством $\text{tr}(AB) = \text{tr}(BA)$, если оба произведения имеют смысл (т. е. размерности матриц позволяют рассматривать оба произведения).

В результате проведенных выкладок получаем, что статистика

$$S^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - k - 1} = \frac{1}{n - k - 1} \hat{\varepsilon}^T \hat{\varepsilon}$$

является несмещенной оценкой дисперсии σ^2 .

Рассмотрим матрицу $E\{(\hat{\beta} - \beta)\hat{\varepsilon}^T\}$, элементы которой представляют собой ковариации случайных величин $\hat{\beta}_j$ и $\hat{\varepsilon}_i$, $j = 0, 1, \dots, k$, $i = 1, 2, \dots, n$. Как нетрудно видеть,

$$\begin{aligned} E\{(\hat{\beta} - \beta)\hat{\varepsilon}^T\} &= (X^T X)^{-1} X^T E\{\varepsilon \varepsilon^T\} P^\perp = \\ &= \sigma^2 (X^T X)^{-1} X^T P^\perp = 0. \end{aligned}$$

Последнее равенство следует из свойств матрицы $P^\perp$. Найденная несмещенная оценка S^2 одиночной дисперсии σ^2 позволяет построить несмещенные оценки всех ковариаций вектора оценок $\hat{\beta}$. Действительно, как было получено ранее, $D\hat{\beta} = \sigma^2(X^T X)^{-1}$, но теперь, заменяя σ^2 на S^2 , получаем несмещенные оценки всех ковариаций и дисперсий вектора $\hat{\beta}$, другими словами, элементы матрицы $S^2(X^T X)^{-1}$ являются несмещенными оценками дисперсий и ковариаций оценок $\hat{\beta}_j$, $j = 0, \dots, k$.

Лемма 3.1. Пусть выполнены все условия из первой и второй групп предположений регрессионного анализа, тогда статистика $(n - k - 1)S^2/\sigma^2$ подчиняется распределению χ^2 с $n - k - 1$ степенями свободы.

Доказательство. Ранее было установлено, что $\hat{\varepsilon} = P^\perp \varepsilon$, где $P^\perp$ — матрица ортогонального проектирования на подпространстве $L^\perp$. Очевидно, что размерность подпространства $L(X_0, \dots, X_k)$ равна $k + 1$. Но тогда размерность подпространства $L^\perp$ равна $n - k - 1$. Выберем в подпространстве $L^\perp$ ортонормированный базис $l_1, \dots, l_{n-k-1}$. Пусть $l = (l_1, \dots, l_{n-k-1})$. Тогда вектор $\hat{\varepsilon}$ единственным образом представим в базисе l :

$$\hat{\varepsilon} = \sum_{r=1}^{n-k-1} \eta_r l_r = l\eta,$$

где $\eta^T = (\eta_1, \dots, \eta_{n-k-1})$.

Очевидно, что

$$\eta = l^T \hat{\varepsilon}.$$

В силу второй группы предположений вектор $\hat{\varepsilon}$ подчиняется многомерному нормальному распределению, но тогда η также подчиняется многомерному нормальному распределению в виду линейности преобразования.

Нетрудно увидеть, что $E\eta = l^T E\hat{\varepsilon} = 0$,

$$D\eta = l^T D\hat{\varepsilon} l = \sigma^2 l^T P^\perp l = \sigma^2 l^T l = \sigma^2 E_{n-k-1},$$

так как $P^\perp$ матрица ортогонального проектирования на $L^\perp$, но все $l_i \in L^\perp$, $i = 1, \dots, n - k - 1$. Кроме того,

$$\hat{\varepsilon}^T \hat{\varepsilon} = \eta^T l^T l \eta = \eta^T \eta.$$

Следовательно, статистики $\hat{\varepsilon}^T \hat{\varepsilon} / \sigma^2$ и $\eta^T \eta / \sigma^2$ распределены одинаково, но из определения распределения χ^2 получаем, что статистика $\eta^T \eta / \sigma^2$ подчиняется распределению χ^2 с $n - k - 1$ степенями свободы. ■

Лемма 3.2. Пусть выполнены предположения первой и второй групп, тогда справедливы утверждения:

1. Вектор оценок $\hat{\beta}$ подчиняется многомерному нормальному распределению, $\hat{\beta} \sim N(\beta, \sigma^2 (X^T X)^{-1})$.
2. Статистика $(n - k - 1)S^2 / \sigma^2$ подчиняется распределению χ^2 с $(n - k - 1)$ степенями свободы и взаимно независима с вектором оценок $\hat{\beta}$.

Доказательство. Первое утверждение сразу следует из линейности явного выражения $\hat{\beta}$ и второй группы предположений:

$$\hat{\beta} = (X^T X)^{-1} X^T Y,$$

линейное преобразование не меняет тип нормального распределения.

Вектор математических ожиданий и дисперсионная матрица были вычислены ранее. Второе утверждение следует из леммы 3.1 и того факта, что $E\{(\hat{\beta} - \beta)\hat{\varepsilon}^T\} = 0$.

Действительно, как нетрудно заметить,

$$\begin{pmatrix} \hat{\beta} \\ \hat{\varepsilon} \end{pmatrix} = \begin{pmatrix} (X^T X)^{-1} X^T \\ P^\perp \end{pmatrix} Y.$$

Следовательно, вектор $(\hat{\beta}^T, \hat{\varepsilon}^T)$ подчиняется многомерному нормальному распределению, но тогда вектора $\hat{\beta}$ и $\hat{\varepsilon}$ взаимно независимы. ■

§ 4. ПОСТРОЕНИЕ ДОВЕРИТЕЛЬНЫХ ИНТЕРВАЛОВ И ПРОВЕРКА СТАТИСТИЧЕСКИХ ГИПОТЕЗ

При выполнении всех условий из первой и второй групп предположений регрессионного анализа справедлива лемма 3.2 предыдущего параграфа, из которой сразу следует, что статистика

$$\frac{\hat{\beta}_j - \beta_j}{S\sqrt{[(X^T X)^{-1}]_{(j+1)(j+1)}}} \sim T_{n-k-1}, \quad j = 0, \dots, k, \quad (4.1)$$

где $[(X^T X)^{-1}]_{(j+1)(j+1)}$ — элемент, стоящий на главной диагонали в строке $j + 1$ и столбце $j + 1$ матрицы $(X^T X)^{-1}$, распределение T_{n-k-1} — распределение Стьюдента с $n - k - 1$ степенями свободы.

Доказательство следует из определения распределения Стьюдента и леммы 3.2.

Из формулы (4.1) следует формула для доверительного интервала с уровнем доверия $1 - \alpha$ для любого параметра β_j , $j = 0, 1, \dots, k$. Доверительный интервал имеет вид:

$$P \left\{ \hat{\beta}_j - t_{1-\frac{\alpha}{2}, n-k-1} S \sqrt{[(X^T X)^{-1}]_{(j+1)(j+1)}} < \beta_j < \right. \\ \left. < \hat{\beta}_j + t_{1-\frac{\alpha}{2}, n-k-1} S \sqrt{[(X^T X)^{-1}]_{(j+1)(j+1)}} \right\} = 1 - \alpha,$$

где $t_{1-\frac{\alpha}{2}, n-k-1}$ — квантиль уровня $1 - \frac{\alpha}{2}$ распределения Стьюдента T_{n-k-1} .

Важное значение имеет проверка гипотез статистической значимости найденных оценок $\hat{\beta}_j$, $j = 0, 1, \dots, n$. Если доверительный интервал для параметра β_j с уровнем доверия $1 - \alpha$ содержит нуль, т. е. если концы доверительного интервала имеют разный знак, то нельзя отклонить гипотезу $H_0: \beta_j = 0$, следовательно, в этом случае найденная оценка $\hat{\beta}_j$ не может быть признана статистически значимой на уровне значимости α . Отсюда следует правило проверки статистической значимости оценки $\hat{\beta}_j$ или, что то же самое, правило проверки гипотезы $H_0: \beta_j = 0$ (справедливость гипотезы означает статистическую незначимость оценки $\hat{\beta}_j$).

Выберем уровень значимости α и вычислим статистику

$$t_{\beta_j} = \frac{\hat{\beta}_j}{S \sqrt{[(X^T X)^{-1}]_{(j+1)(j+1)}}}.$$

Если $|t_{\beta_j}| > t_{1-\frac{\alpha}{2}, n-k-1}$, то гипотеза H_0 отклоняется и оценка $\hat{\beta}_j$ признается статистически значимой на уровне значимости α . Если $|t_{\beta_j}| \leq t_{1-\frac{\alpha}{2}, n-k-1}$, то гипотеза H_0 не отклоняется и оценка $\hat{\beta}_j$ признается статистически незначимой на уровне значимости α .

Проверка статистической значимости оценки $\hat{\beta}_j$ сводится к проверке гипотезы $H_0: \beta_j = 0$.

Нетрудно аналогичным образом проверить более общую гипотезу вида $H_0: \beta_j = \beta_j^{(0)}$. Рассуждая таким же образом, получаем правило проверки гипотезы H_0 на уровне значимости α :

- Если $\frac{|\hat{\beta}_j - \beta_j^{(0)}|}{S \sqrt{[(X^T X)^{-1}]_{(j+1)(j+1)}}} > t_{1-\frac{\alpha}{2}, n-k-1}$, то гипотеза $H_0: \beta_j = \beta_j^{(0)}$ отклоняется на уровне значимости α .
- Если $\frac{|\hat{\beta}_j - \beta_j^{(0)}|}{S \sqrt{[(X^T X)^{-1}]_{(j+1)(j+1)}}} \leq t_{1-\frac{\alpha}{2}, n-k-1}$, то гипотеза $H_0: \beta_j = \beta_j^{(0)}$ принимается на уровне значимости α .

В линейном регрессионном анализе коэффициентом детерминации R^2 называется квадрат коэффициента корреляции между наблюдаемыми значениями показателя $Y^T = (y_1, \dots, y_n)$ и значениями эмпирической функции $\hat{Y}^T = (\hat{y}_1, \dots, \hat{y}_n)$.

Так как $X_0^T = (1, \dots, 1)$ и $\hat{Y} = PY$, причем P — матрица ортогонального проектирования на подпространство $L(X_0, \dots, X_n)$, то $PX_0 = X_0$ или $X_0^T = X_0^T P$.

Но тогда

$$X_0^T \hat{Y} = X_0^T PY = X_0^T Y$$

или

$$\sum_{j=1}^n \hat{y}_i = \sum_{i=1}^n y_i,$$

следовательно,

$$\bar{\hat{y}} = \frac{1}{n} \sum_{i=1}^n \hat{y}_i = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}.$$

По определению

$$\begin{aligned} R^2 &= \frac{(\sum_{i=1}^n (y_i - \bar{y})(\hat{y}_i - \bar{y}))^2}{\sum_{i=1}^n (y_i - \bar{y})^2 \sum_{i=1}^n (\hat{y}_i - \bar{y})^2} = \\ &= \frac{((Y - \bar{y}X_0)^T(\hat{Y} - \bar{y}X_0))^2}{(Y - \bar{y}X_0)^T(Y - \bar{y}X_0)(\hat{Y} - \bar{y}X_0)^T(\hat{Y} - \bar{y}X_0)}. \end{aligned}$$

Заметим, что

$$\begin{aligned} (Y - \bar{y}X_0)^T(\hat{Y} - \bar{y}X_0) &= ((Y - \hat{Y}) + \\ &+ (\hat{Y} - \bar{y}X_0))^T(\hat{Y} - \bar{y}X_0) = (\hat{Y} - \bar{y}X_0)^T(\hat{Y} - \bar{y}X_0), \end{aligned}$$

так как вектор $Y - \hat{Y} \in L^\perp$, а $\hat{Y} - \bar{y}X_0 \in L(X_0, \dots, X_k)$ и, следовательно, вектора $Y - \hat{Y}$ и $\hat{Y} - \bar{y}X_0$ ортогональны, т. е.

$$(Y - \hat{Y})^T(\hat{Y} - \bar{y}X_0) = 0.$$

Но тогда

$$\begin{aligned} R^2 &= \frac{(\hat{Y} - \bar{y}X_0)^T(\hat{Y} - \bar{y}X_0)}{(Y - \bar{y}X_0)^T(Y - \bar{y}X_0)} = \\ &= 1 - \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{(Y - \bar{y}X_0)^T(Y - \bar{y}X_0)}. \quad (4.2) \end{aligned}$$

Для доказательства последнего равенства заметим, что

$$\begin{aligned} (\hat{Y} - \bar{y}X_0)^T(\hat{Y} - \bar{y}X_0) &= \\ &= ((\hat{Y} - Y) + (Y - \bar{y}X_0))^T((\hat{Y} - Y) + (Y - \bar{y}X_0)) = \\ &= (-\hat{\varepsilon} + (Y - \bar{y}X_0))^T(-\hat{\varepsilon} + (Y - \bar{y}X_0)) = \\ &= -\hat{\varepsilon}^T \hat{\varepsilon} + (Y - \bar{y}X_0)^T(Y - \bar{y}X_0), \end{aligned}$$

в виду того, что

$$\begin{aligned}\hat{\varepsilon}^T(Y - \bar{y}X_0) &= \hat{\varepsilon}^T Y - \bar{y}\hat{\varepsilon}^T X_0 = \\ &= \hat{\varepsilon}^T(Y - \hat{Y}) + \hat{\varepsilon}^T \hat{Y} - \bar{y}\hat{\varepsilon}^T X_0 = \hat{\varepsilon}^T \hat{\varepsilon},\end{aligned}$$

так как $\hat{\varepsilon} \in L^\perp$, $\hat{Y} \in L(X_0, \dots, X_k)$, $X_0 \in L(X_0, \dots, X_k)$.

Равенство (4.2) удобно в вычислительном отношении, кроме того, из него видно, что если построенная линейная регрессия идеально точно соответствует наблюдениям, то $Y = \hat{Y}$ и, следовательно, $\hat{\varepsilon} = 0$, но тогда $R^2 = 1$. Наоборот, если $\hat{\beta}_1 = \dots = \hat{\beta}_k = 0$, т.е. линейная регрессия не зависит от $x_1, \dots, x_k$, то $R^2 = 0$. Из определения коэффициента детерминации R^2 сразу следует, что $0 \leq R^2 \leq 1$.

Наиболее важным применением коэффициента R^2 является его использование при проверке гипотезы статистической значимости линейной регрессионной модели в целом, т.е. при проверке гипотезы $H_0: \beta_1 = \dots = \beta_k = 0$. Если указанную гипотезу H_0 нельзя отвергнуть на уровне значимости α , то это означает, что на уровне значимости α построенная линейная регрессия статистически незначима. Малые значения R^2 свидетельствуют против статистической значимости построенной линейной регрессии.

Лемма 4.1. Пусть выполнены обе группы основных предположений линейного регрессионного анализа, тогда в предположении справедливости гипотезы $H_0: \beta_1 = \dots = \beta_k = 0$ статистика

$$F = \frac{R^2}{1 - R^2} \frac{n - k - 1}{k} \sim \mathcal{F}_{k, n-k-1}$$

подчиняется распределению Фишера со степенями свободы k и $n - k - 1$.

Доказательство. Очевидно, что

$$\frac{R^2}{1 - R^2} = \frac{(\hat{Y} - \bar{y}X_0)^T (\hat{Y} - \bar{y}X_0)}{\hat{\varepsilon}^T \hat{\varepsilon}}.$$

При доказательстве леммы 3.2 было показано, что вектора $\hat{\beta}$ и $\hat{\varepsilon}$ взаимно независимы, так как $\hat{Y} = X\hat{\beta}$ и $\bar{y} = \frac{1}{n} \sum_{i=1}^n \hat{y}_i$, то

числитель и знаменатель дроби взаимно независимы. Кроме того, уже было ранее показано, что статистика

$$\frac{(n-k-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \hat{\varepsilon}^T \hat{\varepsilon} \sim \chi_{n-k-1}^2$$

подчиняется распределению χ^2 с $n-k-1$ степенями свободы. Найдем распределение числителя в предположении справедливости гипотезы $H_0: \beta_1 = \dots = \beta_k = 0$. Заметим, что

$$\hat{Y} = PY = X\beta + P\varepsilon = \beta_0 X_0 + P\varepsilon,$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n \hat{y}_i = \beta_0 + \frac{1}{n} X_0^T P\varepsilon = \beta_0 + \frac{1}{n} X_0^T \varepsilon.$$

Тогда

$$\hat{Y} - \bar{y}X_0 = P\varepsilon - \frac{1}{n} X_0^T \varepsilon X_0 = P\varepsilon - \bar{\varepsilon} P X_0 = P(\varepsilon - \bar{\varepsilon} X_0),$$

где $\bar{\varepsilon} = \frac{1}{n} \sum_{i=1}^n \varepsilon_i$, $X_0 = P X_0$.

Как видим,

$$\eta = \hat{Y} - \bar{y}X_0 = P(E_n - \frac{1}{n} T_n) \varepsilon, \quad (4.3)$$

где $T_n = X_0 X_0^T$ — квадратная матрица порядка $n \times n$, все элементы которой являются единицами. Нетрудно заметить, что $\eta \in L(X_0, \dots, X_k)$, кроме того, вектор η ортогонален вектору X_0 , следовательно, $\eta \in L(\tilde{X}_1, \dots, \tilde{X}_k)$, где базисные вектора определяются следующими равенствами $\tilde{X}_r = X_r - \bar{x}_r X_0$, $\bar{x}_r = \sum_{i=1}^n x_{ir}/n$. Нетрудно убедиться, что все вектора $\tilde{X}_r$ ортогональны вектору X_0 , следовательно, вектор X_0 ортогонален подпространству $L(\tilde{X}_1, \dots, \tilde{X}_k)$. Кроме того, из (4.3) следует, что вектор η подчиняется многомерному нормальному распределению, $E\eta = 0$.

Нетрудно проверить, что матрица $P_1 = P(E_n - T_n/n)$ — матрица ортогонального проектирования на подпространство $L(\tilde{X}_1, \dots, \tilde{X}_k)$. Вектор $\eta = P_1 \varepsilon$, следовательно, $D\eta = \sigma^2 P_1$. Все свойства, которые были сформулированы для матрицы P , выполняются и для матрицы P_1 . Выберем в подпространстве

$L(\tilde{X}_1, \dots, \tilde{X}_k)$ ортонормированный базис $d = (d_1, \dots, d_k)$, тогда

$$\eta = \sum_{r=1}^k \xi_r d_r = d\xi, \quad \xi = d^T \eta,$$

$$\xi = (\xi_1, \dots, \xi_k)^T \sim N(0, \sigma^2 E_k),$$

так как

$$D\xi = E\{(d^T \eta)(\eta^T d)\} = \sigma^2 d^T P_1 d = \sigma^2 d^T d = \sigma^2 E_k.$$

Кроме того,

$$\eta^T \eta = \xi^T d^T d \xi = \xi^T \xi.$$

Следовательно, распределения левой и правой частей совпадают. Но тогда из определения распределения χ^2 получаем, что статистика

$$\frac{1}{\sigma^2}(\hat{Y} - \bar{y}X_0)^T(\hat{Y} - \bar{y}X_0) \sim \chi_k^2$$

подчиняется распределению χ^2 с k степенями свободы. ■

Построенная линейная регрессия статистически значима на уровне α тогда и только тогда, когда гипотеза $H_0: \beta_1 = \dots = \beta_k = 0$ отклоняется на уровне значимости α . Поэтому правило проверки статистической значимости линейной регрессии в целом сформулируем следующим образом:

- Если $F = \frac{R^2}{1-R^2} \frac{n-k-1}{k} > F_{1-\alpha; k, n-k-1}$, то гипотеза $H_0: \beta_1 = \dots = \beta_k = 0$ отклоняется на уровне значимости α и, следовательно, построенная линейная регрессия является статистически значимой.
- Если $F \leq F_{1-\alpha; k, n-k-1}$, то гипотеза H_0 принимается, и, следовательно, построенная линейная регрессия является статистически незначимой, здесь $F_{1-\alpha; k, n-k-1}$ — квантиль уровня $1 - \alpha$ распределения Фишера с k и $n - k - 1$ степенями свободы.